



UNIVERSIDAD DE
COSTA RICA

EMat

Escuela de
Matemática

Universidad de Costa Rica
Escuela de Matemática
Departamento de Ciencias Actuariales

Bitácora 1: proyecto grupal

Profesor:
Maikol Solís Chacón

Estudiantes:
Alexandra González Bermúdez
Emily Estefanía Mora Contreras
José Miguel Rodríguez Gómez
Daniela Prado Vargas

Primer semestre
2026

Índice

1	Sección de planificación	2
1.1	Pregunta de investigación	2
1.1.1	Construcción de la idea del proyecto	2
1.1.2	Conceptualización de la idea del proyecto	2
1.1.3	Identificación de las tensiones presentes en la idea del proyecto	3
1.1.4	Reformulación de la idea del proyecto en modo pregunta	4
1.1.5	Argumentación de las preguntas de investigación propuestas	4
1.1.6	Argumentación a través de datos	8
1.2	Revisión bibliográfica	12
1.2.1	Búsqueda de bibliografía	12
1.2.2	Construcción de fichas de literatura	13
1.3	Construcción de la UVE de Gowin	19
1.3.1	Conceptos básicos	20
1.3.2	Teorías y principios	20
1.3.3	Procedimiento	21
2	Escritura de la pregunta de investigación	21
3	Arco narrativo del proyecto	23
4	Definición de la audiencia del proyecto	23
5	Relativo al trabajo en equipo	24
5.1	Posicionamiento del equipo	24
5.2	Rastro de decisiones	24
5.3	Registro del uso de inteligencia artificial	24
5.4	Diario de aprendizaje	25
5.5	Registro del trabajo en equipo	26
	Referencias	27

1 Sección de planificación

1.1 Pregunta de investigación

¿Cómo intervienen las variables de la edad del asegurado, la antigüedad con la aseguradora, el historial de siniestros y las características del vehículo, tanto en la frecuencia como en la severidad de los siniestros y qué factores explican el incremento abrupto en la cantidad de reclamos al momento que el costo de los mismos supera el monto de 900?

1.1.1 Construcción de la idea del proyecto

El planteamiento del presente proyecto consiste en comprobar la existencia de una relación entre las variables de la edad del asegurado, la antigüedad con la aseguradora, el historial de siniestros y las características del vehículo: el tipo, el peso, el largo, así como el valor de este, con el número y la severidad de los siniestros; en caso de confirmar la presencia de algún vínculo entre las variables mencionadas antes, se procederá con su respectivo estudio. Asimismo, se plantea una exploración en torno al incremento abrupto en la cantidad de reclamos al momento que el costo de los mismos supera el monto de 900 unidades monetarias; es importante destacar que dicha eventualidad se identificó durante la etapa de análisis exploratorio, a través de la visualización del gráfico de la cantidad de reclamos de acuerdo al monto reportado.

1.1.2 Conceptualización de la idea del proyecto

A partir de lo propuesto en la pregunta de investigación y el apartado de la construcción de la idea del proyecto, se profundizará en el significado de las principales palabras que sostienen el planteamiento extendido. Cabe recalcar que la totalidad de las definiciones se tomarán de la página web de la Real Academia Española (2026) (Real Academia Española, 2026), a excepción del concepto de severidad, dado que su interpretación actuarial difiere de la empleada usualmente en el lenguaje.

En la categoría de verbos, se destacan las siguientes palabras:

- Intervenir: efecto de tomar parte en un asunto.
- Comprobar: confirmar la veracidad o exactitud de algo.
- Estudiar: examinar atentamente.
- Explicar: dar a conocer las causas de algo, llegar a entender su razón.

En la categoría de sustantivos, se destacan las siguientes palabras:

- Variable: que varía o puede variar. Magnitud que puede tomar un valor cualquiera de los comprendidos en un conjunto.
- Asegurado: que está protegido de las consecuencias de un riesgo mediante un seguro.
- Siniestro: suceso que produce un daño o una pérdida material considerables.
- Incremento: aumento, acrecentamiento o extensión de algo.

- Severidad: “monto de las pérdidas que se generan a partir de un evento ocurrido” (León Cruz, 2025).
- Frecuencia: repetición mayor o menor de un acto o de un suceso. Número de veces que se repite un proceso periódico por unidad de tiempo.
- Relación: conexión, correspondencia de algo con otra cosa.

En la categoría de adjetivos, se destaca la siguiente palabra:

- Abrupto: violento o rudo.

1.1.3 Identificación de las tensiones presentes en la idea del proyecto

En el presente apartado se abordarán las tensiones que se derivan del planteamiento propuesto en la idea de investigación, entendiéndose por tensiones a todos aquellos elementos que potencialmente podrían representar un obstáculo en el pleno desarrollo del proyecto. Las tensiones identificadas se desprenden de dos aspectos principales: el origen y las características de la base de datos, así como la convivencia simultánea de múltiples variables. Se procede a detallar cada una de ellas en los párrafos siguientes.

El componente del cual surgen la mayoría de tensiones corresponde a la base de datos. En primer lugar, si bien los autores de apellido Lledó y Pavía acompañaron la publicación del archivo con una descripción de las variables que lo conforman y un breve detalle de su origen, aún se desconoce información crucial. No se esclarece el proceso adoptado para la obtención de los datos, así tampoco se extiende una noción al lector respecto a la aseguradora de la cual provienen los mismos. De igual forma, no se especifica la divisa que mide los montos de las variables monetarias contenidas en la tabla.

Los datos están formateados en una hoja de cálculo que abarca las principales actividades de la cartera de seguros de automóviles no de vida durante un período de tres años completos (de noviembre de 2015 a diciembre de 2018). Este conjunto de datos consta de 105.555 filas y 30 columnas. Cada fila representa una transacción de póliza, mientras que cada columna representa una variable distinta. (Lledó & Pavía, 2024)

En segundo lugar, se encuentra la especificidad de los datos en cuestiones espaciales y temporales. En lo que respecta a lo espacial, se tiene la noción de que los datos provienen de una región concreta, puesto que los autores se desempeñan como profesores del Departamento de Economía Aplicada en la Universidad de Valencia; de manera que, generalizar los resultados a otros contextos puede traer consigo importantes dificultades. Por otro lado, al abarcar únicamente el periodo de 2015 a 2018, no se comprenden eventualidades importantes como la pandemia y el panorama geopolítico que impera, en consecuencia, los resultados podrían no ser del todo aplicables a la actualidad.

Después, el segundo componente desencadenante de tensiones se sitúa en la interacción simultánea de múltiples variables. En la pregunta de investigación se propone estudiar el incremento abrupto en la cantidad de reclamos al momento que el costo de los mismos supera la cantidad de 900, con el objetivo de determinar cuáles factores explican dicho escenario. No obstante, frente al hecho de que la base de datos está integrada por 30 variables para cada una de las pólizas transaccionadas, la intención de definir cuáles de ellas intervienen de manera considerable en el evento de estudio es potencialmente complejo.

1.1.4 Reformulación de la idea del proyecto en modo pregunta

A partir de los elementos versados en los apartados anteriores, se proponen las siguientes preguntas de investigación:

1. ¿Cómo intervienen las variables de la edad del asegurado, la antigüedad con la aseguradora, el historial de siniestros y las características del vehículo, tanto en la frecuencia como en la severidad de los siniestros y qué factores explican el incremento abrupto en la cantidad de reclamos al momento que el costo de los mismos supera el monto de 900?
2. ¿Cómo varía la distribución de la frecuencia y la severidad de los siniestros reportados de acuerdo a los perfiles de los asegurados y las condiciones del seguro, y qué factores explican dichas diferencias?
3. ¿Qué patrones se pueden encontrar en la ocurrencia de los siniestros reportados que permitan distinguir distintos niveles de riesgo entre los asegurados?
4. ¿Cómo intervienen la potencia, el largo y el peso de los vehículos en la frecuencia y la severidad de los siniestros reportados?

De las preguntas de investigación estructuradas antes, se seleccionó la número uno como herramienta para el presente proyecto. Seguidamente, se procede a precisar las razones por las que las demás fueron descartadas en términos de la viabilidad que poseen en vínculo a la base de datos escogida y los intereses de investigación del equipo.

En primera instancia, la segunda propuesta se descartó puesto que plantea un enfoque descriptivo en su mayoría, centrado en analizar cómo varía la distribución de la frecuencia y la severidad de los siniestros entre distintos perfiles. Sin embargo, no incorpora de manera explícita un objetivo explicativo más profundo ni la identificación de fenómenos específicos de interés dentro de los datos, por ejemplo, los cambios abruptos en el comportamiento de los reclamos.

Después, se prescindió de la tercera opción, dado el hecho de que se enfoca principalmente en la identificación de patrones y en la clasificación de asegurados según niveles de riesgo. No obstante, esta formulación no contempla los intereses iniciales del equipo: el estudio de la relación de variables específicas con la frecuencia y la severidad de los siniestros. En vista de lo anterior, no es posible abordar la base de datos de la manera deseada.

Por último, la cuarta pregunta se descartó debido a que está contenida de forma implícita en la propuesta seleccionada, además, solo contempla la potencia, el largo y el peso de los vehículos, ignorando otros factores de suma importancia como la edad del asegurado o la zona de circulación.

1.1.5 Argumentación de las preguntas de investigación propuestas

A continuación, para cada una de las preguntas planteadas en el apartado anterior, se construirán una serie de argumentos y contrargumentos con la finalidad de evaluar la viabilidad de dichos caminos investigativos. Tanto los argumentos como los contraargumentos responden a tres áreas de evaluación: la lógica, que corresponde a la óptica científica; la ética, que verifica la transparencia además de la solidez del análisis; y finalmente la emocional, la cual se encarga de garantizar la trascendencia de las propuestas para la población correspondiente.

1.1.5.1 1. ¿Cómo intervienen las variables de la edad del asegurado, la antigüedad con la aseguradora, el historial de siniestros y las características del vehículo, tanto en la frecuencia como en la severidad de los siniestros y qué factores explican el incremento abrupto en la cantidad de reclamos al momento que el costo de los mismos supera el monto de 900?

Contraargumentos

Lógica: la pregunta combina múltiples variables explicativas que conviven simultáneamente, asimismo, aborda dos dimensiones distintas de análisis: la frecuencia y la severidad. En vista de lo anterior, determinar la relación existente entre dos variables específicas cualesquiera posee una considerable complejidad. Además, el incremento abrupto en la cantidad de reclamos a partir de que el costo de los mismos supera las 900 unidades monetarias, se identificó a partir de la observación de un único gráfico durante el análisis exploratorio, de manera que representa una evidencia empírica inicial y podría no ser generalizable ni representar un punto de cambio real sin un análisis estadístico a mayor detalle.

Ética: el uso de variables como la edad o el historial de siniestros puede implicar riesgos de segmentación injusta si no se justifica adecuadamente su inclusión, especialmente si se utilizan para la toma de decisiones que afecten a los asegurados.

Emocional: el énfasis en el incremento abrupto en la cantidad de reclamos al momento que el costo de los mismos supera el monto de 900 puede percibirse como una visión reduccionista de la población asegurada, sin considerar el contexto individual detrás de cada siniestro, lo que podría generar una percepción de trato impersonal. De igual forma, el hecho de brindar un menor foco al comportamiento de la cantidad de reclamos previo a dicha eventualidad, potencialmente podría generar una sentimiento de invalidación en los individuos que se encuentran en dicho tramo.

Argumentos

Lógica: a través del uso de los modelos estadísticos tanto adecuados como adaptados para cada una de las dimensiones de análisis, es posible identificar claramente la manera en que las variables de la edad del asegurado, la antigüedad con la aseguradora, el historial de siniestros y las características del vehículo inciden en la frecuencia y la severidad de los siniestros. Además, el análisis del comportamiento de la cantidad de reclamos cuando el costo de los mismos supera el monto de 900 unidades monetarias, representa una oportunidad para explorar posibles patrones en la distribución de los costos de los reclamos.

Ética: la selección responsable de las variables, acompañada de una evaluación de posibles sesgos en los datos, brinda una mayor certeza de que el análisis no promueva la discriminación injusta, sino que se base en criterios transparentes. Asimismo, el uso adecuado de la información permite generar conclusiones que contribuyan a mejorar la equidad en la toma de decisiones dentro del ámbito asegurador.

Emocional: si bien es imposible considerar el contexto individual de los siniestros bajo estudio, debido a cuestiones de tiempo y de acceso a la información: la aseguradora se mantiene en el anonimato; la comunicación clara y explícita de aquello que se está abordando en el proyecto y el motivo por el cual decidió abordarse, propicia un análisis de mayor confianza, a la vez que extiende a la población asegurada del estudio la validación correspondiente: sus eventualidades son significativas, sin embargo, el proyecto sigue una delimitación.

Conclusiones: la propuesta de analizar la intervención de las variables de la edad del asegurado, la antigüedad con la aseguradora, el historial de siniestros y las características del vehículo, tanto en la frecuencia como en la severidad de los siniestros, además del estudio del incremento abrupto en la cantidad de reclamos al momento que el costo de los mismos supera el monto de 900; debe integrar un enfoque estadístico adecuado al igual que adaptado para cada una de las dimensiones de análisis (lógica), junto con una consideración ética en el uso de las variables y la posible presencia de sesgos en los datos (ética), y

una interpretación de los resultados, que si bien es imposible que contemple cada caso particular, extienda a la población asegurada bajo estudio la validación correspondiente en torno a sus eventualidades, evitando las percepciones de trato impersonal (emocional). Asimismo, el análisis de la cantidad de reclamos cuando su costo alcanza las 900 unidades monetarias, debe entenderse como una observación empírica inicial que requiere de análisis estadístico adicional. Esta combinación permite generar conclusiones más completas, responsables y útiles para la toma de decisiones en el ámbito asegurador.

1.1.5.2 2. ¿Cómo varía la distribución de la frecuencia y la severidad de los siniestros reportados de acuerdo a los perfiles de los asegurados y las condiciones del seguro, y qué factores explican dichas diferencias?

Contraargumentos

Lógica: de manera similar a la propuesta anterior, la presente pregunta considera tanto la frecuencia como la severidad, los cuales corresponden a dos elementos distintos e implica un análisis de dos dimensiones. Además, se recurre a variables amplias y abiertas: los perfiles de los asegurados y las condiciones del seguro; de esta forma, la construcción de un análisis claro y específico se puede dificultar en gran medida.

Ética: el análisis de las diferencias entre los perfiles de los asegurados podría implicar el uso de variables sensibles, ya sea la edad u otras características personales. En vista de esto, es posible la creación de segmentaciones poco oportunas o la reproducción de sesgos presentes en los datos.

Emocional: el enfoque de la diferenciación entre los perfiles de los asegurados puede resultar reduccionista para los individuos bajo estudio, de manera que su identidad y contexto se limiten a determinadas características obtenidas a partir de la base de datos. En consecuencia, los sujetos podrían ser agrupados en categorías que no responden a sus realidades individuales, generando incomodidad o una percepción de trato impersonal.

Argumentos

Lógica: análogamente a la pregunta anterior, el uso de los modelos estadísticos tanto adecuados como adaptados para cada una de las dimensiones de análisis, acompañado de la explícita y delimitada definición de las variables de los perfiles de los asegurados y las condiciones del seguro, es posible edificar un análisis preciso además de estructurado, que se encargue de capturar las diferencias en la frecuencia y la severidad de los siniestros.

Ética: la práctica de un proceso de selección de variables que responda a criterios de responsabilidad y de protección de la sensibilidad de los sujetos bajo estudio, junto a la revisión de posibles sesgos en los datos, propiciaría que el análisis se aleje de promover algún tipo de discriminación y se base en principios estadísticos transparentes.

Emocional: si bien es imposible considerar el contexto individual de los sujetos bajo estudio dado el acceso limitado a la información, se puede optar por construir los distintos perfiles en base a elementos meramente relacionados a los seguros contratados por estos, de manera que no se contemplen ciertas características relativas a su identidad. Así, los grupos responderían solo a cuestiones de la contratación del aseguramiento, lejos de reunir a los individuos en categorías que no respondan a sus realidades individuales.

Conclusiones: la propuesta de analizar cómo varía la distribución de la frecuencia y la severidad de los siniestros reportados de acuerdo a los perfiles de los asegurados y las condiciones del seguro debe procurar una adecuada delimitación de las variables a las cuales recurre, al igual que el uso de los modelos estadísticos apropiados que permitan capturar las diferencias de la frecuencia y la severidad de los siniestros de manera clara (lógica). Asimismo, necesita considerar los posibles riesgos de sesgo, además de la potencial

discriminación asociada al uso de determinadas variables (ética). Por último, se precisa una comunicación de los resultados que sea comprensible, acertada y respetuosa con la información sensible para los sujetos bajo estudio (emocional). Esta integración favorece un análisis más equilibrado y transparente, que no se limita a la descripción de las diferencias, sino que también contribuye a una mejor comprensión y aplicación de los resultados.

1.1.5.3 3. ¿Qué patrones se pueden encontrar en la ocurrencia de los siniestros reportados que permitan distinguir distintos niveles de riesgo entre los asegurados?

Contraargumentos

Lógica: se parte del supuesto de que ya existen patrones en los datos, no obstante, aún no se ha realizado un estudio que confirme tal cosa. Comenzar asumiendo la existencia de estos patrones puede generar un sesgo en la interpretación de los datos, además de propiciar la construcción de conclusiones forzadas.

Ética: para buscar estos patrones se requiere de decisiones metodológicas importantes, como la selección de las variables y la elección del modelo. Estas decisiones pueden influir en los resultados finales, ya que, si no se justifican de forma adecuada, es posible que el análisis pierda transparencia.

Emocional: hacer énfasis en la detección de patrones genera la percepción de que se está simplificando el fenómeno, de manera que la complejidad de los siniestros se ve reducida únicamente a comportamientos recurrentes. Lo anterior podría generar que los resultados se perciban como distantes o excesivamente técnicos.

Argumentos:

Lógica: la identificación de patrones permite encontrar estructuras en los datos sin asumir relaciones desde el inicio. A partir del uso de herramientas estadísticas como los estadísticos de resumen, la visualización de los datos, las distribuciones muestrales y los modelos estadísticos adecuados, es posible analizar el comportamiento de los siniestros con base en la información disponible. De esta manera, se pueden construir niveles de riesgo basados en los datos y así facilitar la organización, al igual que el análisis de grandes cantidades de información.

Ética: cuando el análisis se desarrolla con una metodología claramente definida y documentada, se fortalece la transparencia del proceso y la solidez de los resultados. Además, una interpretación cuidadosa de los resultados permite evitar que los patrones identificados respondan únicamente a particularidades de la muestra, asegurando que tengan un sustento adecuado en los datos.

Emocional: la presentación clara y estructurada de los resultados, enfocada en explicar tendencias generales, puede facilitar la comprensión del fenómeno estudiado. Esto contribuye a que los hallazgos se perciban como información útil y aplicable, en lugar de interpretaciones arbitrarias o desconectadas de la realidad.

Conclusiones: el análisis de patrones en la ocurrencia de los siniestros debe abordarse sin asumir desde el inicio la existencia de resultados específicos, permitiendo que los datos guíen el proceso (lógica). Asimismo, es necesario mantener una metodología bien definida y una interpretación cuidadosa de los resultados, de manera que el análisis sea transparente y coherente con la información disponible (ética). Finalmente, una presentación clara y enfocada en tendencias generales permite que los resultados sean más comprensibles y útiles, evitando que se perciban como excesivamente técnicos o alejados del fenómeno estudiado (emocional). De esta forma, se obtiene un análisis consistente además de aplicable dentro del contexto del estudio.

1.1.5.4 4. ¿Cómo intervienen la potencia, el largo y el peso de los vehículos en la frecuencia y la severidad de los siniestros reportados?

Contraargumentos

Lógica: la pregunta se enfoca en variables específicas del vehículo, lo cual reduce la complejidad respecto a otras propuestas; sin embargo, continúa abordando simultáneamente la frecuencia y la severidad, lo que implica el análisis de dos dimensiones distintas. Asimismo, estas variables podrían estar correlacionadas entre sí: los vehículos más pesados tienden a ser más largos, de forma que se puede dificultar la identificación del efecto individual de cada variable, además de generar problemas de interpretación en los modelos.

Ética: el uso de variables técnicas requiere de un manejo responsable en cuanto a la calidad y la precisión de los datos, ya que errores en su medición o registro podrían afectar la validez de los resultados. Asimismo, es importante garantizar que las conclusiones derivadas del análisis se interpreten correctamente y no se extrapolen más allá de lo que los datos permiten.

Emocional: el análisis centrado en las características técnicas del vehículo puede percibirse como distante o poco relacionado con la experiencia personal del asegurado, lo que podría dificultar la conexión entre los resultados del estudio y la realidad de los individuos.

Argumentos

Lógica: el enfoque en variables específicas como la potencia, el largo y el peso permite construir un análisis más delimitado y manejable. Mediante modelos estadísticos adecuados, es posible evaluar cómo estas variables influyen tanto de forma individual como en conjunto sobre la frecuencia y la severidad de los siniestros.

Ética: el uso de variables técnicas permite un análisis basado en datos objetivos, lo que hace el proceso más claro y fácil de seguir. Además, permite desarrollar conclusiones fundamentadas en datos observables del vehículo, promoviendo una interpretación responsable y alineada con los alcances reales del estudio.

Emocional: al centrarse en características del vehículo, el análisis puede percibirse con mayor neutralidad, siendo menos invasivo para los asegurados. Asimismo, los resultados podrían representar información útil en el proceso de toma de decisiones, tanto para la aseguradora como para los propios usuarios.

Conclusiones

El análisis de la influencia de la potencia, el largo y el peso de los vehículos sobre la frecuencia y la severidad de los siniestros constituye una propuesta viable debido a su delimitación y enfoque en variables observables del vehículo (lógica). Además, requiere un manejo cuidadoso de la calidad de los datos y una interpretación adecuada de los resultados para asegurar su validez y coherencia (ética). Finalmente, su carácter técnico favorece una percepción más neutral del análisis, facilitando su aceptación por parte de la población asegurada (emocional). En conjunto, esta propuesta permite generar hallazgos claros, aplicables y responsables dentro del contexto asegurador.

1.1.6 Argumentación a través de datos

1.1.6.1 Fuente de información

Los datos se obtuvieron de la Universitat de València a través de la página Mendeley Data (Lledó & Pavía, 2024), desde donde se descargaron tres archivos: dos en formato CSV y uno en formato Excel.

El primer archivo se titula “Descriptive of the variables.xlsx” el cual contiene la descripción de cada una de las variables/columnas presentes en la base de datos. Por su parte, el segundo archivo se titula “Motor vehicle insurance data.csv”, y reúne la información relacionada a las pólizas de seguros. Finalmente, el tercer archivo se titula “sample type claim.csv”, y este presenta información detallada sobre los siniestros, donde se incluye el identificador (ID), el monto total de reclamos en un año, el costo de una parte de los reclamos y la categorización del tipo de reclamo.

1.1.6.2 Contexto temporal y espacial de los datos

La base de datos abarca información relacionada con pólizas de seguros de autos, cuyo inicio se registra entre 1980 y 2017, mientras que las renovaciones de dichas pólizas se registran entre 2015 y 2019. Además de esto, se dispone de información sobre los siniestros ocurridos entre 2016 y 2018. En cuanto al contexto espacial, los datos se sitúan en la ciudad de Valencia, España.

1.1.6.3 Facilidad de obtener la información

Como se mencionó anteriormente, la información fue obtenida de la página “Mendeley Data”, desde donde puede descargarse libremente sin necesidad de realizar una solicitud previa, ya que se encuentra disponible de forma gratuita para cualquier usuario.

Sin embargo, algunas columnas como “length” y “weight” presentan valores faltantes (NA). Además, varias columnas asociadas a fechas, entre ellas “Date_start_contract”, se encuentran registradas como tipo *character* en lugar de tipo *date*, por lo que es necesario realizar una conversión previa.

1.1.6.4 Población de estudio

La población estudio de esta investigación corresponde a los asegurados que poseen al menos una póliza de seguro vehicular en la ciudad de Valencia. Dentro de esta población, se incluyen distintos tipos de vehículos, entre ellos motocicletas, furgonetas, turismos (automóviles de cuatro a cinco asientos) y vehículos agrícolas, tanto de zonas rurales como urbanas. Adicionalmente, se contempla información asociada a los siniestros ocurridos entre 2016 y 2018.

1.1.6.5 Muestra observada

La muestra observada posee un total de 105555 observaciones, de las cuales 53502 corresponden a identificaciones únicas, donde cada identificación representa a un asegurado distinto. Asimismo, se tienen 30 columnas (variables) en total, y registra tanto asegurados que presentaron siniestros como aquellos que no reportaron eventos durante el período analizado.

1.1.6.6 Unidad estadística o individuos

La unidad estadística principal corresponde a la póliza por año, donde cada fila de los datos corresponde a una anualidad del contrato del asegurado. Esto implica que un mismo asegurado puede aparecer más de una vez en las filas, dependiendo del número de años en que mantuvo vigente su póliza, lo que explica la diferencia entre las 105555 observaciones totales y las 53502 únicas. Dado que puede aparecer múltiples veces, esto da la posibilidad de ver la evolución de la póliza a lo largo del tiempo.

Por otra parte, en el archivo “sample type claim.csv”, la unidad estadística es el tipo de siniestro asociado a cada individuo.

1.1.6.7 Descripción de las variables de la tabla

1.1.6.7.1 Motor vehicle insurance data

- **ID** (Identificador): Corresponde al número de identificación interna asignada a cada contrato anual de un asegurado
- **Date_start_contract** (Fecha de inicio del contrato): Fecha de inicio del contrato del asegurado, tiene formato día/mes/año
- **Date_last_renewal** (Fecha de la última renovación): Fecha de la última renovación del contrato, tiene formato día/mes/año
- **Date_next_renewal** (Fecha de la próxima renovación): Fecha de la próxima renovación del contrato, tiene formato día/mes/año
- **Distribution_channel** (Canal de distribución): Clasifica el canal a través del cual se contrató la póliza. 0 si fue un Agente y 1 para Corredores de seguros.
- **Date_birth** (Fecha de nacimiento): Fecha de nacimiento del asegurado declarada en la póliza, tiene formato día/mes/año.
- **Date_driving_licence** (Fecha de la licencia de conducir): Fecha de expedición del permiso de conducir de la persona asegurada, tiene formato día/mes/año.
- **Seniority** (Antigüedad): Número total de años que el asegurado ha estado asociado con la entidad aseguradora.
- **Policies_in_force** (Pólizas en vigencia): Número total de pólizas que el asegurado posee con la entidad aseguradora en el periodo de referencia.
- **Max_policies** (Máximo de pólizas): Número máximo de pólizas que el asegurado ha tenido alguna vez en vigor con la entidad aseguradora.
- **Max_products** (Productos máximos): Número máximo de productos que el asegurado ha mantenido simultáneamente en un momento dado.
- **Lapse** (Cancelación): Número de pólizas que el cliente ha cancelado o se le han cancelado por impago en el año de vencimiento actual, excluyendo aquellas que han sido reemplazadas por otra póliza.
- **Date_lapse** (Fecha de cancelación): Fecha de cancelación; fecha de terminación del contrato, tiene formato día/mes/año
- **Payment** (Método de pago): Último método de pago de la póliza de referencia. El 1 representa un proceso administrativo semestral y 0 indica un método de pago anual.
- **Premium** (Prima): Monto de la prima neta asociada a la póliza durante el año en curso.
- **Cost_claims_year** (Costo de siniestro del año): Costo total de los siniestros de la póliza de seguro durante el año en curso.
- **N_claims_year** (Número de siniestro en el año): Número total de siniestros ocurridos para la póliza de seguro durante el año en curso.

- **N_claims_history** (Número de siniestros histórico): Número total de siniestros declarados durante toda la vigencia de la póliza de seguro.
- **R_Claims_history** (Ratio de siniestros histórico): Ratio del número de siniestros declarados para la póliza específica con respecto a la duración total (en años completos) de la póliza en vigor.
- **Type_risk** (Tipo de riesgo): Tipo de riesgo asociado a la póliza. Cada valor corresponde a un tipo de riesgo específico: 1 para motocicletas, 2 para furgonetas, 3 para turismos y 4 para vehículos agrícolas.
- **Area** (Zona): Representa la zona de circulación del vehículo. 0 para rural y 1 para urbano (más de 30.000 habitantes) en términos de condiciones de tráfico.
- **Second_driver** (Segundo conductor): 1 si hay varios conductores habituales declarados, o 0 si solo se declara un conductor.
- **Year_matriculation** (Año de matriculación): Año de matriculación del vehículo.
- **Power** (Potencia): Potencia del vehículo medida en caballos de fuerza.
- **Cylinder_capacity** (Capacidad de cilindrada): Cilindrada del vehículo.
- **Value_vehicle** (Valor del vehículo): Valor de mercado del vehículo al 31 de diciembre del 2019.
- **N_doors** (Número de puertas): Número total de puertas del vehículo.
- **Type_fuel** (Tipo de combustible): Tipo específico de combustible utilizado para el vehículo. P para Gasolina y D para Diésel.
- **Length** (Longitud): Longitud en metros del vehículo.
- **Weight** (Peso): Peso en kilogramos del vehículo.

1.1.6.7.2 Sample type claim

- **ID** (Identificador): Mismo identificador que en el archivo principal. Permite vincular cada siniestro con la póliza asociada.
- **Cost_claims_year** (Costo de siniestros del año): Costo total de los siniestros de la póliza durante el año en curso.
- **Cost_claims_by_type** (Costo de siniestros por tipo): Costo asociado a un tipo específico de reclamo dentro del siniestro.
- **Claims_type** (Tipo de siniestro): Clasificación del tipo de reclamo como: asistencia en viaje, rotura de lunas, reclamación, negligencia, robo, incendio, lesiones, etc.

Cada fila del archivo “Motor vehicle insurance data” corresponde a una anualidad del contrato de un seguro, es decir, a un año de cobertura asociado a un asegurado específico. Esto implica que un mismo asegurado puede aparecer en múltiples filas, una por cada año que haya tenido una póliza activa. Esta estructura resulta especialmente útil para la investigación, ya que permite analizar la evolución temporal de la severidad y frecuencia de los siniestros de un mismo asegurado, así como incorporar el historial de reclamos a través de las columnas N_claims_history y R_claims_history para predecir comportamientos futuros.

Las columnas pueden clasificarse según el tipo de información que contienen. Por ejemplo, existen variables temporales como `Date_start_contract` o `Date_last_renewal`; variables de siniestralidad como `N_claims_year` y `Cost_claims_year` que pueden emplearse para modelar la frecuencia de los siniestros o calcular el costo promedio por siniestro. También hay variables de historial como `N_claims_history` y `R_claims_history`, que permiten observar la evolución del comportamiento del asegurado a lo largo del tiempo.

Cada celda posee un valor específico para un asegurado en un año determinado, lo que permite identificar, por ejemplo, el monto de prima pagado en un periodo concreto. A su vez, las filas aportan información sobre la evolución del riesgo a través del tiempo, facilitando la identificación de patrones en el comportamiento de los asegurado. En particular, la variable `Cost_claims_year` permite identificar los casos que superan el umbral de los €900, mientras que otras variables como `Seniority`, `Date_birth`, `Type_risk` y `N_claims_history` permiten evaluar si existe relación entre ellas y la frecuencia y severidad de los siniestros. Asimismo, las celdas poseen valores concretos que permitirán estimar la relación entre los predictores y lo obtenido en los resultados. De esta manera, las filas, variables/columnas y celdas se relacionan directamente con la pregunta de investigación.

1.2 Revisión bibliográfica

1.2.1 Búsqueda de bibliografía

Las principales herramientas de búsqueda utilizadas para la revisión de literatura fueron las siguientes:

- <https://scholar.google.com/>
- <http://google.com/>
- <https://data.mendeley.com/>
- <https://www.scielo.org/es/>
- <https://www.scirp.org/>

Algunas combinaciones de palabras claves utilizadas para la revisión fueron las siguientes:

- insurance + claims + frequency
- claim + severity + distribution
- vehicle + insurance + risk factors
- frequency + severity + model
- insurance + claim + severity
- claim + frequency + distribution
- claim + severity + modeling
- age + insurance + claims
- driver + age + risk
- vehicle + characteristics + claims
- insurance + risk + factors
- claim + predictors + insurance

1.2.2 Construcción de fichas de literatura

i Omari et al. (2018)

Nivel descriptivo

Título: Modeling the Frequency and Severity of Auto Insurance Claims Using Statistical Distributions

Autores: Cyprian Ondieki Omari, Shalyne Gathoni Nyambura, Joan Martha Wairimu Mwangi Department of Statistics and Actuarial Science, Dedan Kimathi University of Technology, Nyeri, Kenya.

Año: 2018

Nombre del tema: Frecuencia y la severidad de siniestros en seguros de autos.

Clasificación: Metodológica.

Este estudio propone una metodología que podría adaptarse de manera efectiva en el proyecto que se está planteando. Esto, ya que el tema es parecido, frecuencia y severidad de seguros de automóviles. El artículo propone un procedimiento concreto para seleccionar distribuciones, estimar parámetros y evaluar ajuste, más que desarrollar una teoría nueva o revisar la evolución histórica del problema.

Resumen en una oración: Comparación de distribuciones estadísticas y estimación de parámetros para modelar frecuencia y severidad en reclamaciones vehiculares.

Argumento central: El artículo establece que la frecuencia y severidad de los reclamos en el campo de los seguros de autos deben modelarse por separados, utilizando las distribuciones adecuadas a las características observadas. Además, establece que la selección del modelo debe basarse en estimación por máxima verosimilitud, pruebas de bondad de ajuste y criterios de información; en sus datos, la severidad se ajusta mejor con una lognormal y la frecuencia con distribuciones binomial negativa y geométrica.

Problemas con el argumento o el tema: Los autores señalan que uno de los principales problemas al modelar reclamaciones de seguros es que los datos no siguen distribuciones simples debido a su comportamiento observado. Los datos presentan asimetría positiva, el fenómeno de “colas pesadas” y una alta concentración de valores cero en la frecuencia de siniestros. Esto dificulta el uso de distribuciones clásicas como Poisson o binomial, ya que en varios casos no logran un ajuste adecuado según las pruebas de bondad de ajuste realizadas. Por eso, finalmente los autores utilizan una distribución lognormal.

Nivel analítico

Conexión con mi proyecto: En general, el proyecto planteado, al igual que en el artículo, también separa variables de frecuencia de siniestros, como N_claims_year o N_claims_history, y variables de severidad, como Cost_claims_year o el costo promedio por siniestro. Por tanto, este artículo sirve como potencial referencia metodológica para modelar frecuencia y severidad con distribuciones distintas, adecuadas para su comportamiento. Además, permite ver ejemplos de distribuciones que utilizan máxima verosimilitud y otras pruebas de bondad de ajuste.

Lo que NO dice el autor: El artículo no incorpora variables como edad, tipo de vehículo o historial de reclamos, como se plantea hacer en este proyecto. Tampoco profundiza en como modela la dependencia de un mismo asegurado a lo largo del tiempo, lo que sí es importante ya que los asegurados pueden aparecer múltiples veces dependiendo de las pólizas. Esto es una limitación importante, ya que se espera poder describir la distribución global de los reclamos así como entender su comportamiento usando información individual.

Contraste con otra fuente: Este artículo coincide con lo planteado por Frees (2021). En ese sentido, la frecuencia y la severidad de los siniestros deben analizarse por separado, ya que representan procesos aleatorios distintos. Frees explica que la frecuencia suele modelarse con distribuciones discretas como Poisson o binomial negativa, mientras que la severidad requiere distribuciones continuas, como gam-

ma, Pareto o lognormal. La diferencia es que Omari et al. llevan ese planteamiento a una aplicación empírica concreta y muestran, mediante pruebas de bondad de ajuste, que en sus datos la distribución lognormal describe mejor la severidad y la binomial negativa la frecuencia.

Evaluación de aplicabilidad (escala 1–5): 4

La metodología es aplicable porque parte del mismo problema básico de la investigación: modelar frecuencia y severidad en seguros de autos con datos observados. Técnicamente, su separación entre variable discreta de conteo y variable continua positiva encaja bien con los datos con los que se va a trabajar. Aún así, el artículo trabaja sobre ajuste de distribuciones marginales y no desarrolla modelos con covariables, por eso únicamente se usará esta investigación como base para la metodología.

Pregunta que le haría al autor: ¿Por qué la distribución lognormal ofreció un mejor ajuste para la severidad de los siniestros en comparación con otras distribuciones evaluadas, y qué características específicas de los datos influyeron más en ese resultado?

Resumen argumentativo: El problema que los autores intentan resolver es cómo escoger distribuciones adecuadas para representar la frecuencia y la severidad de reclamaciones en seguros de automóviles, ya que una mala elección afecta reservas, primas y proyecciones financieras. Su solución funciona bien como punto de partida porque sigue un procedimiento ordenado: seleccionar familias de distribuciones posibles, estimar parámetros por máxima verosimilitud y comparar ajustes con pruebas estadísticas e indicadores de información. Para el contexto del proyecto, este enfoque sí resulta útil, sobre todo para la etapa exploratoria y para justificar por qué la frecuencia y la severidad deben analizarse por separado. Sin embargo, se queda corto cuando el objetivo pasa de describir la distribución de los datos a explicar diferencias entre asegurados o a comprender comportamiento futuro usando variables del historial. En este proyecto, esa limitación es importante porque se quieren aprovechar columnas como `N_claims_history` y `R_claims_history` para estudiar evolución del riesgo a través del tiempo.

i Frees (2021)

Nivel descriptivo

Título: *Loss Data Analytics*

Autores: Edward Frees.

Año: 2021

Nombre del tema: Fundamentos para el análisis de frecuencia y severidad de siniestros en el campo de seguros.

Clasificación: Teórica.

El documento desarrolla principios básicos y generales de modelación de variables y fundamentos probabilísticos que ciertamente sirven como base conceptual para distintos tipos de análisis.

Resumen en una oración: Explica cómo modelar frecuencia y severidad de pérdidas mediante distribuciones probabilísticas.

Argumento central: Este es un libro que presenta información acerca de el análisis de pérdida. Para el contexto de este proyecto, el documento sostiene que el riesgo asegurador puede analizarse separando el número de siniestros (frecuencia) y el costo de cada uno (severidad), utilizando distribuciones probabilísticas distintas para cada componente según la naturaleza de los datos y lo que se reporta al observarlos.

Problemas con el argumento o el tema: El autor señala que uno de los principales retos es seleccionar distribuciones adecuadas porque los datos de seguros suelen presentar asimetría, valores extremos y heterogeneidad entre asegurados, lo que dificulta que un único modelo funcione en todos los contextos.

Nivel analítico

Conexión con mi proyecto: Este documento se relaciona directamente con la investigación porque proporciona el fundamento teórico para analizar la variable *N_claims_year* como frecuencia y *Cost_claims_year* como severidad dentro de la base de datos de seguros vehiculares. Además, justifica el uso de distribuciones discretas para frecuencia y distribuciones continuas para severidad, que son precisamente los enfoques que se quieren considerar en el estudio.

Lo que NO dice el autor: Aunque explica bien la lógica general de frecuencia y severidad, no profundiza en cómo adaptar esos modelos cuando existe un alto porcentaje de ceros o cuando los datos provienen de mercados específicos con características regulatorias distintas, como puede ocurrir en una base de datos particular y real de seguros de automóviles.

Contraste con otra fuente: Este libro complementa el artículo de Omari et al. (2018), porque Frees presenta el marco teórico general de frecuencia–severidad, mientras que Omari et al. muestran una aplicación empírica concreta donde se verifica que la binomial negativa y la lognormal ofrecen mejor ajuste para datos reales.

Evaluación de aplicabilidad (escala 1–5): 3

La metodología es altamente aplicable porque el modelo frecuencia–severidad coincide directamente con la estructura de la base de datos; sin embargo, requiere ajustes adicionales para manejar características específicas que presenten los mismos.

Pregunta que le haría al autor: Cuando varias distribuciones parecen razonables teóricamente para severidad, ¿qué criterio considera más importante para seleccionar una en una base de datos real?

Resumen argumentativo: El problema principal que aborda el autor es cómo representar matemáticamente el riesgo en seguros cuando las pérdidas no son determinísticas. Su propuesta funciona porque separa dos procesos aleatorios distintos: cuántos siniestros ocurren y cuánto cuesta cada uno. Esta división permite asignar distribuciones diferentes según el comportamiento de cada variable. En el contexto del proyecto, esta estructura resulta útil porque las variables de frecuencia y severidad están claramente diferenciadas en la base de datos. Sin embargo, el texto no resuelve completamente cómo proceder cuando los datos presentan exceso de ceros o comportamientos extremos muy marcados, como sucede en un estudio real como el de Omari et al. (2018).

i Melgar & Guerrero (2005)

Nivel descriptivo

Título: Los siniestros en el seguro del automóvil: un análisis econométrico aplicado.

Autores: M.C. Melgar Hiraldo y F.M. Guerrero Casas.

Año: 2005.

Nombre del tema: Identificación de factores determinantes de la frecuencia de siniestros y análisis de la correlación entre niveles de cobertura y siniestralidad.

Clasificación: Metodológica.

Se eligió esta clasificación porque el artículo no solo desarrolla la base teórica de la asimetría de la información (selección adversa y riesgo moral), sino que también aplica un modelo econométrico de datos de conteo (específicamente, un modelo binomial negativo inflado de ceros) a una muestra real de 60,000 pólizas, con el fin de identificar variables significativas en la siniestralidad.

Resumen en una oración: Aplicación de modelos de conteo inflados de ceros para analizar cómo el perfil del conductor, las características del vehículo y el nivel de cobertura influyen en la frecuencia de los siniestros declarados.

Argumento central: La explicación sobre por qué utilizar el modelo ZINB es la más adecuada para el análisis de estos datos, donde la cantidad de ceros en el número de siniestros es muy grande, ya que

algunas personas no reportan que ocurrió el siniestro o, simplemente, no han tenido ninguno.

Problemas con el argumento o el tema: Los autores mencionan que no consideran el posible efecto del fraude, lo cual podría sesgar la medición de la siniestralidad real (Melgar & Guerrero, 2005). Además, señalan limitaciones en la disponibilidad de información, ya que mencionan que las aseguradoras en España tienen menos información sobre sus clientes en comparación con las de otros países, lo que dificulta la investigación (Melgar & Guerrero, 2005).

Nivel analítico

Conexión con mi proyecto: El artículo se relaciona directamente con la pregunta de investigación, ya que analiza variables equivalentes a las planteadas en el proyecto: edad del asegurado, experiencia o antigüedad del conductor y distintas características del vehículo. Además, proporciona una base metodológica sólida para el uso de modelos inflados de ceros (ZINB), especialmente en contextos donde existe una alta proporción de pólizas sin siniestros, situación que también se ha observado en las variables N_claims_year y N_claims_history en la base de datos utilizada.

Lo que NO dice el autor: El estudio no aborda la severidad de los siniestros, enfocándose exclusivamente en la frecuencia. Asimismo, no analiza comportamientos específicos en los montos de los reclamos, como incrementos abruptos o efectos umbral (por ejemplo, el caso de los 900 mencionado en la pregunta de investigación), ya que su variable dependiente corresponde únicamente al número de eventos.

Contraste con otra fuente: Mientras que Goldburd et al. (2025) proponen el uso de modelos lineales generalizados (GLM) como enfoque estándar para modelar la frecuencia y severidad de los siniestros, Melgar & Guerrero (2005) analizan un contexto en el que este tipo de modelos puede resultar insuficiente. En particular, cuando los datos presentan un elevado número de ceros y comportamientos no observados, los autores proponen el uso de modelos inflados de ceros, que permiten representar la siniestralidad de una manera más flexible. De esta forma, su propuesta puede interpretarse como una extensión necesaria en contextos donde no se cumplen sus supuestos básicos.

Evaluación de aplicabilidad (escala 1–5): 4.

El artículo es altamente aplicable para el análisis de la frecuencia de los siniestros y para justificar la selección de variables relevantes del perfil del asegurado y del vehículo. No obstante, su principal limitación es la ausencia de un análisis de severidad, que constituye una dimensión clave en la pregunta de investigación. Adicionalmente, su aplicabilidad puede verse limitada por el alcance metodológico del curso, ya que algunos de los modelos o técnicas propuestas podrían no ser abordados en el desarrollo del mismo, lo cual restringe su implementación práctica en este trabajo.

Pregunta que le haría al autor: ¿Podría la decisión de no declarar siniestros menores explicar la presencia de vacíos o incrementos abruptos en ciertos rangos de costos (como el umbral de 900), en comparación con la frecuencia observada de accidentes?

Resumen argumentativo: El problema que Melgar y Guerrero (2005) intentan resolver es la dificultad de modelar el número de siniestros en seguros de automóviles cuando los datos presentan gran cantidad de ceros y mucha heterogeneidad entre asegurados. Los modelos tradicionales, como el Poisson o la binomial negativa, resultan limitados porque no diferencian adecuadamente los tipos de ceros ni capturan bien la variabilidad de los datos. La solución propuesta, basada en el modelo binomial negativo inflado de ceros (ZINB), permite separar a los individuos que no presentan siniestros por razones estructurales de aquellos expuestos al riesgo, lo cual mejora el ajuste del modelo en contextos con muchos ceros. Esta metodología es pertinente para el proyecto, ya que también se trabaja con datos de frecuencia con alta presencia de ceros, donde modelos inflados pueden ofrecer estimaciones más precisas. No obstante, su implementación puede ser más compleja y depender de la calidad de los datos y de las herramientas metodológicas disponibles en el curso. En este trabajo se adoptará el uso de modelos

más flexibles para datos de conteo y el criterio de selección basado en las características empíricas de los datos.

i Goldburd et al. (2025)

Nivel descriptivo

Título: Generalized Linear Models for Insurance Rating

Autores: Mark Goldburd, Anand Khare, Dan Tevet y Dmitriy Guller.

Año: 2025.

Nombre del tema: Modelación de la frecuencia y severidad de siniestros usando Modelos Lineales Generalizados para tarifar seguros.

Clasificación: Metodológica.

Se eligió esta etiqueta porque no solamente habla de la teoría de la frecuencia y severidad, sino que da una guía de cómo modelarlos estadísticamente con modelos lineales generalizados (GLM), además, el capítulo 3 es sobre el proceso de construir el modelo.

Resumen en una oración: Guía para construir planes de tarificación utilizando Modelos Lineales Generalizados

Argumento central: A pesar de que el libro trata sobre la tarificación para seguros; los elementos metodológicos que utiliza, tales como la selección de las distribuciones y el uso de la variables, son los mismos que se necesitan para responder parte de la pregunta de investigación; específicamente cómo intervienen las variables en la frecuencia y severidad de los siniestros.

Problemas con el argumento o el tema: Primero, los autores del libro identificaron que los GLM se ajustan asumiendo que los datos son totalmente fiables, además, no tienen en cuenta la escasez de datos en los que se basa; por lo que si se tienen pocos datos, podría generarse un coeficiente poco confiable. Además de esto, los GLM asumen que la aleatoriedad de los datos no está coorelacionada, algo que no puede pasar si, por ejemplo, varios asegurados son afectados por un mismo factor, como un desastre natural.

Nivel analítico

Conexión con mi proyecto: Este libro se relaciona en gran medida con el proyecto, una parte de la pregunta de investigación es ver cómo influyen variables como la edad del asegurado, la antigüedad con la aseguradora, el historial de siniestros y las características del vehículo, en la frecuencia y severidad de los siniestros; en el libro, en el capítulo 2, sección 2.7, se habla de las distribuciones para la frecuencia y para la severidad, además, en las sección 2.4 se habla de cómo tratar con variables tanto categóricas como continuas. Luego, en el capítulo 5 se habla de elegir la variable objetivo, ya sea la frecuencia o la severidad, cómo elegir su distribución, cómo seleccionar y transformar variables. Finalmente, en el Capítulo 7 se explica cómo validar el modelo.

Lo que NO dice el autor: La pregunta que no se responde para el proyecto es la explicación sobre el incremento abrupto de los reclamos por año en el umbral de los €900, además el libro asume que los datos están limpios y perfectos para modelar, tampoco profundiza en la limpieza de los datos ni manejo de los NA.

Contraste con otra fuente: En referencia a la ficha de Patel (2025) en la que se da una introducción al tema de coorelación, se señala que la principal limitación es que se asume una relación lineal entre las variables y no aplica para las relaciones no lineales u otras interacciones más complejas. Goldburd et al. (2025) trata esta limitación en la sección 5.4 del libro, titulada como “Transformation of Variables” en donde en la primer sección explican cómo detectar si una variable tiene relación no lineal con la variable que se está utilizando; y en las siguientes 4 secciones se explica cómo tratar la no linealidad

por medio de diferentes métodos los cuales son: binning, términos polinomiales, funciones lineales por partes y natural cubic splines. De esta forma, Goldburd et al. (2025) resuelven la limitación identificada en el trabajo de Patel (2025)

Evaluación de aplicabilidad (escala 1–5): 4.5.

El libro de Goldburd et al. (2025) explica cómo modelar tanto la frecuencia como la severidad de siniestros por medio de GLM. Además, explica cómo tratar con variables categóricas y continuas, verificar si existen relaciones no lineales y cómo tratarlas y también se incluye una sección en donde se explica cómo validar los modelos, algo fundamental para verificar que el modelo esté bien.

Pregunta que le haría al autor: ¿Se podría descubrir por qué hay un aumento abrupto del número de reclamos por año en €900 y cómo lo haría?

Resumen argumentativo: Lo que los autores intentan resolver es explicar cómo hacer un plan de tarificación utilizando GLM, donde explican desde el manejo de los datos, hasta la creación y validación de modelos. La solución propuesta por los autores sirve para la investigación parcialmente, pues posee capítulos sumamente útiles como lo pueden ser el capítulo 2 y el 5, los cuales están relacionados directamente con la investigación, específicamente la parte de la relación entre distintas variables y la frecuencia y severidad de los siniestros. Pero el libro está destinado a la tarificación de seguros, tema que no trata nuestra investigación. Además de esto, el libro no aborda la otra parte de la pregunta de investigación, el aumento abrupto en la cantidad de reclamos por año en los €900. De este trabajo se utilizará la metodología propuesta para modelar la frecuencia y severidad, también se utilizará las técnicas para la transformación de variables; además de los métodos para detectar y tratar relaciones no lineales entre las variables; finalmente, no se utilizará la parte de tarificación de seguros.

Patel (2025)

Nivel descriptivo

Título: *Correlation Analysis: exploring Relationships between Variables*

Autor: Shivani Patel

Año: 2025

Nombre del tema: introducción al análisis de correlación entre variables.

Clasificación: metodología.

El análisis de correlación permite comprobar la existencia de una relación lineal entre variables específicas, lo cual constituye una metodología de interés para el proyecto.

Resumen en una oración: introduce el concepto de correlación, su relevancia, su interpretación y las distintas aplicaciones que posee.

Argumento central: esclarece lo relativo al concepto de correlación, una herramienta esencial en el estudio de las relaciones lineales entre variables. Asimismo, se destaca su importancia en una diversidad de contextos, situando a la modelación en dicho conglomerado.

Problemas con el argumento o el tema: la autora enfatiza que el análisis de correlación asume una relación lineal entre las variables y no aplica para las relaciones no lineales u otras interacciones complejas. Asimismo, menciona que el análisis de correlación podría estar influenciado por los valores atípicos, al igual que por las anomalías presentes en los datos.

Nivel analítico

Conexión con mi proyecto: la pregunta de investigación plantea comprobar la existencia de una relación entre las variables de la edad del asegurado, la antigüedad con la aseguradora, el historial de siniestros y las características del vehículos, con la frecuencia y la severidad de los siniestros. De esta manera, el análisis de correlación representa una potencial herramienta para efectuar dicha comprobación.

Lo que NO dice el autor: no se detallan los diversos procedimientos a seguir en vías de evaluar la correlación de variables. El archivo no brinda una metodología concreta, sino que solo brinda una introducción al tema.

Contraste con otra fuente: en referencia al recurso titulado *Modelos predictivos del riesgo y aplicaciones a los seguros*, no se identifica relación alguna entre el contenido de ambos archivos. Exploran temáticas distintas, a la vez que su finalidad difiere: el presente recurso únicamente brinda una introducción al concepto de correlación, mientras que el artículo profundiza en la modelación del riesgo a partir del análisis predictivo de cuantiles. Sus enfoques son completamente diferentes.

Evaluación de aplicabilidad (escala 1–5): 4.

El análisis de correlación representa una herramienta importante para el estudio de las relaciones lineales entre variables dadas.

Pregunta que le haría al autor: ¿Cuál metodología del análisis de correlación utilizaría para estudiar las relaciones entre las variables especificadas en la pregunta con la frecuencia y la severidad de los siniestros?

Resumen argumentativo: se brinda al lector un preámbulo del análisis de correlación, los diferentes tipos, su interpretación, así como sus aplicaciones en varios escenarios. El análisis de correlación posee una potencial aplicabilidad en el contexto del proyecto, pues ayuda a determinar la existencia de relaciones lineales entre variables, una parte del objetivo de la pregunta de investigación.

1.3 Construcción de la UVE de Gowin

Para la construcción de la misma, se plantea lo solicitado de acuerdo a dos teorías y principios, al menos tres conceptos relacionados y un borrador del procedimiento en la parte metodológica planteada de acuerdo a los autores Novak et al. (2002). La figura es de elaboración propia, y se muestra a continuación.



Figura 1: UVE de Gowin

1.3.1 Conceptos básicos

Cuatro conceptos básicos en el estudio consisten en: severidad, frecuencia, siniestro y riesgo. Estas palabras fueron debidamente definidas en la sección 1.1.2., excepto riesgo. De acuerdo a la Real Academia Española, riesgo se define como: “Contingencia o proximidad de un daño.”, o, una definición alternativa, “Cada una de las contingencias que pueden ser objeto de un contrato de seguro.” (Real Academia Española, 2026).

Estos conceptos se consideran fundamentales, ya que el enfoque del estudio se centra en la frecuencia y la severidad de los siniestros, por lo que es necesario comprender adecuadamente el fenómeno analizado. En este contexto, los siniestros constituyen los eventos base que generan las pérdidas; la frecuencia mide el número de veces que estos ocurren, mientras que la severidad se refiere al costo asociado a cada uno. A partir de estos elementos se construye el concepto de riesgo, entendido como la incertidumbre sobre la ocurrencia y la magnitud de dichas pérdidas.

1.3.2 Teorías y principios

De acuerdo con Frees (2021), el análisis de los siniestros en seguros se fundamenta en el modelo de frecuencia-severidad, el cual establece que el riesgo puede descomponerse en dos partes: la frecuencia y la

severidad. Esta división de componentes permite estudiar de manera más precisa el comportamiento de los siniestros.

Asimismo, la teoría de la modelación probabilística plantea que tanto la frecuencia como la severidad pueden describirse mediante distribuciones de probabilidad adecuadas, y se pueden aproximar mediante las mismas. En particular, la distribución de Poisson es comúnmente utilizada para modelar la frecuencia de los siniestros, mientras que distribuciones continuas como la Gamma permiten representar la severidad.

A partir de estas teorías, se derivan principios fundamentales en el campo de los seguros. En primer lugar, se reconoce que el comportamiento de los siniestros es inherentemente aleatorio, por lo que debe ser modelado mediante herramientas probabilísticas que permitan capturar la incertidumbre asociada a su ocurrencia y magnitud. En segundo lugar, se establece que el riesgo puede descomponerse en dos componentes esenciales: la frecuencia y la severidad.

1.3.3 Procedimiento

Para la parte metodológica, se utilizó como referencia el estudio de Omari et al. (2018), el cual establece que dos metodologías útiles y altamente utilizadas en estudios actuariales relacionados con frecuencia y severidad son el análisis exploratorio de datos y la modelación estadística, que es lo que se plantea para este proyecto.

2 Escritura de la pregunta de investigación

En consideración de lo construido hasta el momento, la pregunta seleccionada para ser el eje central del proyecto es la siguiente:

¿Cómo intervienen las variables de la edad del asegurado, la antigüedad con la aseguradora, el historial de siniestros y las características del vehículo, tanto en la frecuencia como en la severidad de los siniestros y qué factores explican el incremento abrupto en la cantidad de reclamos al momento que el costo de los mismos supera el monto de 900?

Los criterios de selección se basaron en tres elementos principales: la claridad de la propuesta, el factor del tiempo, así como la delimitación temática. En lo que respecta a la claridad de la propuesta, se requiere que el lector sea capaz de comprender a partir de la lectura de la pregunta, el problema que el proyecto busca solucionar. Después, es de suma importancia considerar el tiempo disponible para la elaboración del trabajo, en tal sentido, es necesario que el problema a resolver sea lo suficientemente complejo en vías de elaborar su solución durante la completitud del semestre, mas su complejidad no debe excederse de manera que el tiempo disponible para trabajar sea insuficiente. Por último, la delimitación temática de la pregunta debe ser clara y apropiada; es ideal que el lector conozca a raíz de la pregunta los aspectos que el proyecto abordará y estos a su vez deben concordar con el elemento evaluado antes, el factor del tiempo. Tras la valoración de los criterios explicados, se concluyó que la pregunta seleccionada los satisfacía de manera óptima; en ese aspecto la propuesta enmarca explícitamente lo que pretende estudiar: la relación entre variables determinadas y un evento específico en la cantidad de reclamos de acuerdo al costo de los mismos, asimismo, la dificultad del problema que plantea resolver está adecuada al periodo del cual que se dispone para finalizar el proyecto.

Por otro lado, la conceptualización de la pregunta está en sintonía con los intereses investigativos del equipo, a la vez que los conceptos a los cuales recurre son de entendimiento para la mayoría de las

poblaciones. Los verbos principales son intervenir y explicar, donde se entiende al primero como el efecto de tomar parte en un asunto y al segundo como dar a conocer las causas de algo o llegar a comprender su razón. Así, el objetivo de la propuesta consiste en determinar la manera en que las variables detalladas toman parte en la frecuencia y la severidad de los siniestros, además de comprender las razones por las cuales se presenta el incremento abrupto en la cantidad de reclamos al momento que el costo de los mismos supera el monto de 900 unidades monetarias. Cabe destacar que la frecuencia y la severidad tienen un rol esencial en el contexto del aseguramiento, sobre esto Guillen et al. (2021) mencionan que “el análisis del riesgo estudia los sucesos extraordinarios, qué los causa y cómo mitigar su probabilidad de ocurrencia. En seguros, básicamente importa la frecuencia y la severidad de los siniestros”.

Como se mencionó antes, un criterio de selección de la pregunta fue la claridad de la propuesta, en busca de que el problema a solucionar se conozca mediante su respectiva lectura, por lo tanto, la argumentación a efectuar igualmente se desprende de esta. La propuesta cuenta con dos elementos de estudio: la relación entre determinadas variables de la base de datos y el comportamiento inusual de la cantidad de reclamos cuando el costo de los mismos alcanza un monto de 900 unidades monetarias. En primer lugar, se busca verificar la existencia de un vínculo entre las variables de la edad del asegurado, la antigüedad con la aseguradora, el historial de siniestros y las características del vehículo: el tipo, el peso, el largo, así como el valor de este, con la frecuencia y la severidad de los siniestros. Dicha verificación puede efectuarse con las pruebas de correlación a convenir, lo que a su vez conforma una argumentación sólida, pues como menciona Patel (2025), (traducción propia), “el análisis de correlación evalúa el grado de asociación o de relación entre las variables, indicando cómo los cambios en una variable están relacionados con los cambios en otra variable”. De comprobarse la existencia de algún vínculo, se procederá a determinar la naturaleza del mismo mediante el uso de los modelos estadísticos tanto adecuados como adaptados para cada una de las dimensiones de análisis. Entender la relación entre las variables bajo estudio es fundamental en el contexto de la toma de decisiones, ya que al acceder a un mayor entendimiento de los múltiples elementos que conviven simultáneamente en un entorno como una aseguradora de vehículos, permite a los tomadores de decisiones “evaluar los potenciales impactos y tomar decisiones informadas” (Patel, 2025), de manera que se protejan las obligaciones de la entidad con los asegurados.

En segundo lugar, se estudiará el comportamiento de la cantidad de reclamos cuando el costo de los mismos supera el monto de 900 unidades monetarias. Durante la etapa del análisis exploratorio, se identificó un incremento abrupto en la cantidad de reclamos en el momento especificado, así, surgió el interés de examinar tal evento. Se pretende determinar qué elementos propician su presencia, a través de un estudio exhaustivo de las variables en la base de datos. Una vez identificados los aspectos incidentes, se detallarán las razones por las que se concluyó el factor explicativo de estos respecto al evento de interés.

Finalmente, al revisar las creaciones de otros autores hasta ahora, mediante búsquedas a partir de palabras claves como frecuencia, severidad, cantidad de reclamos y seguros automovilísticos; se identificó que la mayoría de las producciones gira en torno al análisis y la predicción del riesgo en el aseguramiento. Específicamente en lo relativo a seguros automovilísticos, se encontró un artículo de autoría de estudiantes de Ciencias Actariales de la Universidad de Costa Rica, quienes trabajaron en el ajuste de la distribución de las pérdidas para seguros de accidentes automovilísticos. Asimismo, los autores poseen una inclinación a trabajar en la modelación de distintas variables, dentro de ellas se sitúan la frecuencia de las reclamaciones, el pago por concepto de las reclamaciones, la predicción del riesgo, así como la predicción de la siniestralidad.

3 Arco narrativo del proyecto

El problema que nadie ha resuelto completamente aún es cómo interactúan las variables del asegurado y del vehículo para explicar la frecuencia y severidad de los siniestros, así como los cambios abruptos en el comportamiento de los reclamos.

4 Definición de la audiencia del proyecto

Esta investigación está dirigida a un actuario de seguros de no vida, que tenga interés por comprender cómo variables como la edad del asegurado, su antigüedad con la aseguradora, el historial de siniestros y características del vehículo, influyen tanto en la frecuencia como en la severidad de siniestros; y qué factores causan incrementos abruptos en los reclamos. Esta semana le diría a un actuario de seguros que se está construyendo un modelo GLM para estimar la prima de riesgo pura, además se han identificado variables como la antigüedad del asegurado con la compañía aseguradora y la potencia del vehículo que podrían ser predictores importantes; también, se está investigando qué factores están asociados con el aumento abrupto de reclamos por año que superan los €900.

5 Relativo al trabajo en equipo

5.1 Posicionamiento del equipo

Para la elaboración de este proyecto, el equipo se considera adecuado para abordar el tema debido a la motivación compartida por profundizar en el análisis estadístico dentro del contexto asegurador. En particular, se busca trabajar con información que permita no solo reforzar los conocimientos adquiridos en el curso, sino también iniciar un acercamiento a otras áreas de la carrera, como seguros de no vida. Asimismo, existe un interés por comprender el funcionamiento general de una aseguradora, especialmente en lo relacionado con la ocurrencia de siniestros y los factores que influyen en su comportamiento, lo que permite integrar tanto la aplicación de herramientas estadísticas como la interpretación de los resultados en un contexto más amplio.

5.2 Rastro de decisiones

Para esta bitácora se tomaron decisiones tanto temáticas como metodológicas. En primer lugar, de las preguntas planteadas en la sección 1.1.4., se seleccionó la primera, ya que permite abordar tanto la frecuencia y la severidad de los siniestros, incorporando además un fenómeno atípico identificado; este es, el incremento abrupto en la cantidad de reclamos cuando el costo supera las 900 unidades monetarias. Las demás preguntas fueron descartadas por presentar un alcance más limitado, o al menos no el que se deseaba directamente. La segunda tenía un enfoque principalmente descriptivo, la tercera se alejaba del análisis de variables específicas al centrarse en patrones generales de riesgo, y la cuarta restringía el estudio únicamente a características del vehículo.

Una vez definida la pregunta, se seleccionaron variables del asegurado (edad, antigüedad con la aseguradora e historial de siniestros) y del vehículo (tipo, peso, largo y valor), por su relevancia teórica y disponibilidad en la base de datos. Además, al detectarse durante el análisis exploratorio previo un cambio abrupto en la frecuencia de reclamos a partir del umbral de 900, se decidió incorporar este comportamiento como un fenómeno específico de estudio.

En el aspecto metodológico, se tomó como referencia, principalmente, el estudio de Omari, donde se señala que el análisis exploratorio de datos y la modelación estadística son metodologías ampliamente utilizadas en estudios relacionados a la frecuencia y severidad de siniestros, especialmente en el campo de seguros de no-vida. A partir de ello, se decidió adoptar ambas estrategias como base del proyecto por su naturaleza.

Finalmente, se estableció que el análisis se realizará en dos etapas: primero, mediante pruebas de asociación o correlación para explorar relaciones preliminares entre variables; y después, mediante modelación estadística, considerando que la frecuencia corresponde a conteos y la severidad a montos monetarios.

5.3 Registro del uso de inteligencia artificial

Para la sección 1.2.1., se consultó a ChatGPT por palabras claves para buscar información en los repositorios y buscadores web. En este caso el *prompt* que se utilizó fue el siguiente:

- Prompt: “Cuáles pueden ser algunas palabras claves que permitan una mejor búsqueda de artículos científicos, libros y otros recursos acerca de la frecuencia y severidad de los siniestros en el campo de seguros de auto”

La respuesta exacta de ChatGPT fue la siguiente:

“Podrías responderlo así, claro y directo: Algunas palabras clave útiles para buscar información sobre frecuencia y severidad de siniestros en seguros de auto son: claim frequency, claim severity, motor insurance, automobile insurance risk, loss distribution, frequency-severity model, Poisson distribution insurance, Gamma distribution claim severity y actuarial loss modeling. Estas palabras permiten encontrar artículos tanto teóricos como aplicados sobre modelación estadística de siniestros.” “Extra: para que encuentres artículos mejores en bases como Google Scholar o ScienceDirect, combina así: claim frequency AND motor insurance claim severity AND actuarial modeling automobile insurance loss distribution Eso normalmente da resultados mucho más útiles.”

A partir de esto, se contruyeron las mezclas de palabras para la búsqueda que se pueden encontrar en la sección 1.2.1., las cuales se utilizaron para encontrar los artículos, libros y recursos que se utilizaron para la revisión bibliográfica.

Por otro lado, durante la elaboración de la sección 1.1.5, Argumentación de la pregunta, se utilizó ChatGPT como apoyo para mejorar la redacción de algunos párrafos. En particular, se ingresaron los párrafos de forma individual con el fin de evaluar posibles mejoras en su claridad y coherencia. A partir de las respuestas generadas, se revisaron los cambios sugeridos, distinguiendo entre aquellos que contribuían a comunicar la idea de manera más clara y aquellos que resultaban innecesarios o alteraban el sentido original. En consecuencia, se adoptaron únicamente las modificaciones pertinentes, manteniendo el estilo propio. El uso de esta herramienta facilitó la organización de ideas y contribuyó a fortalecer la escritura académica del documento.

5.4 Diario de aprendizaje

La presente sección está diseñada para registrar los aprendizajes adquiridos durante la elaboración de la bitácora, lo anterior a través de oraciones concisas que respondan a la siguiente pregunta: ¿Qué sabemos ahora que no sabíamos al inicio del proyecto? Dichas oraciones proceden a detallarse como sigue:

- Tras una observación superficial de los datos, se descubrió que hay una concentración de siniestros cuya severidad registra un monto de cero unidades monetarias para la aseguradora: en muchas ocasiones los asegurados no efectúan la reclamación del seguro.
- Aprendí que los modelos lineales generalizados no sirven solamente para la tarificación de seguros, sino que también sirven para modelar la frecuencia y severidad de siniestros y que existen métodos para tratar con variables que no se relacionan linealmente.
- Con la revisión bibliográfica, se identificó que los datos de seguros suelen presentar comportamientos irregulares, como muchos ceros o valores extremos, por lo que no siempre pueden modelarse con distribuciones simples.
- Tras la revisión bibliográfica, se descubrió que para datos con muchos ceros, como en este caso el conteo de siniestros, el modelo de Poisson, aunque es el más común, puede no funcionar adecuadamente ya que asume igualdad entre la media y la varianza; sin embargo, la presencia de muchos ceros aumenta la variabilidad y rompe este supuesto, por lo que es necesario recurrir a modelos más flexibles.

5.5 Registro del trabajo en equipo

Nombre	Contribuciones
Alexandra González Bermúdez	Conceptualización de la idea de investigación Identificación de tensiones Escritura de la pregunta de investigación Diario de aprendizaje Construcción de fichas bibliográficas Registro del trabajo en equipo Revisión de la redacción del documento
Nombre	Contribuciones
Emily Estefanía Mora Contreras	Reformulación de la idea de investigación en modo pregunta Construcción de la Uve de Gowin Diario de aprendizaje Construcción de fichas bibliográficas Rastro de decisiones Revisión de la redacción del documento Construcción del citado y referencias en BibTeX
Nombre	Contribuciones
Daniela Prado Vargas	Arco narrativo del proyecto Identificación de tensiones Argumentación de la pregunta de investigación Diario de aprendizaje Construcción de fichas bibliográficas Posicionamiento del equipo
Nombre	Contribuciones
José Miguel Rodríguez Gómez	Definición de la idea de investigación Reformulación de la idea de investigación en modo Argumentación a través de datos Diario de aprendizaje Construcción de fichas bibliográficas Definición de la audiencia del proyecto

Referencias

- Frees, E. W. (2021). *Loss Data Analytics*. Springer. <https://openacttexts.github.io/LDASpanish/>
- Guillen, M., Láinez, M., Pérez-Marín, A., & Sánchez, E. (2021). Modelos predictivos del riesgo y aplicaciones a los seguros. *Nuevos métodos de predicción económica con datos masivos*, 93-109.
- León Cruz, A. T. (2025). *Definición y Cálculo de Severidad en Seguros*. Scribd. <https://es.scribd.com/document/818151852/1-2-Severidad-X-Morbilidad-ATLC>
- Lledó, J., & Pavía, J. M. (2024). *Dataset of an actual motor vehicle insurance portfolio* (Versión 2). Mendeley Data. <https://doi.org/10.17632/5cxyb5fp4f.2>
- Novak, J. D., Gowin, D. B., & Otero, J. (2002). *Aprendiendo a aprender* (Vol. 33). Martínez Roca Barcelona.
- Omari, C. O., Nyambura, S. G., & Mwangi, J. M. W. (2018). *Modeling the frequency and severity of auto insurance claims using statistical distributions*. <https://doi.org/10.4236/jmf.2018.81012>
- Patel, S. (2025). *Correlation Analysis: Exploring Relationships between Variables*. <https://doi.org/10.13140/RG.2.2.16000.34561>
- Real Academia Española. (2026). *Diccionario de la lengua española*. <https://dle.rae.es>