

Intervención de la edad del asegurado, la antigüedad con la aseguradora, el historial de siniestros y las características del vehículo en la frecuencia y la severidad de los siniestros

Alexandra González, Estefanía Mora, Daniela Prado y José Miguel Rodríguez

ALEXANDRA.GONZALEZBERMUDEZ@ucr.ac.cr, EMILY.MORACONTRERAS@ucr.ac.cr,

DANIELA.PRADOVARGAS@ucr.ac.cr, JOSE.RODRIGUEZGOMEZ@ucr.ac.cr

RESUMEN

La tarificación en seguros de automóviles requiere comprender los factores que se asocian con la siniestralidad, compuesta por la frecuencia y la severidad de los reclamos. Este estudio analiza cómo las características del asegurado y del vehículo se relacionan con estos dos componentes, agregando una tercera capa de estudio: el análisis del incremento abrupto en la frecuencia de reclamos alrededor del umbral de 900 euros. Se analizó una base de datos de 105.555 pólizas de una aseguradora española, con información entre 1980 y 2018, realizando un análisis descriptivo completo de los datos. Para explorar las relaciones, se utilizaron correlaciones de Spearman con intervalos de confianza de Fisher, junto con un modelo de distribución mixta de tres componentes: costos nulos, costos moderados y costos altos; ajustado con el paquete *fitdistrplus* de R y validado con intervalos asintóticos. Los resultados muestran que ciertas variables, como el historial de reclamos, poseen una relación significativa con la siniestralidad, mientras que otras, como la edad del asegurado o el valor del vehículo, presentan una correlación despreciable. El modelo de distribución mixta demostró que los costos se caracterizan adecuadamente mediante una distribución Lognormal, con un mejor ajuste en comparación al de otras distribuciones: la Gamma, la Weibull y la Pareto. Asimismo, dicho modelo captura la estructura de los costos, reiterando la relevancia del umbral de 900 euros. Los intervalos de confianza para los parámetros mostraron amplitudes reducidas, 0,0302; 0,0213; 0,0436 y 0,0308, para $\mu_1, \sigma_1, \mu_2, \sigma_2$ respectivamente, confirmando la estabilidad de las estimaciones.

PALABRAS CLAVE: siniestralidad en seguros de automóviles, frecuencia de siniestros, severidad de siniestros, historial de reclamos, factores de riesgo.

INTRODUCCIÓN

En el acontecer actuarial, predomina la existencia de múltiples variables, tanto cuantitativas como cualitativas, que interactúan simultáneamente en un espacio compartido. En particular, en el ámbito asegurador automotriz, resulta imprescindible comprender la manera en que las diversas variables se relacionan con la ocurrencia y el costo de los siniestros reportados, ya que estos últimos elementos son ejes fundamentales en la determinación de las primas cobradas a los asegurados, a la vez que una correcta fijación de las primas potencia la sostenibilidad financiera de las aseguradoras. Las variables de la edad del asegurado, la antigüedad con la aseguradora, el historial de siniestros y las características del vehículo, tienden a estar contenidas en la mayoría de las bases de datos pertenecientes a las aseguradoras automotrices, de manera que estudiar su intervención sobre la frecuencia y la severidad de los siniestros cobra una evidente importancia bajo el contexto planteado.

El presente proyecto posee el objetivo de analizar la relación entre las variables mencionadas en el párrafo anterior con dos variables respuesta: la frecuencia y la severidad de los siniestros. Lo anterior se

desarrolló a partir de la base de datos de autoría de Lledó & Pavía (2024), la cual muestra la información relacionada con una aseguradora situada en Valencia, España; con entradas que comprenden el periodo entre 1980 y 2018. Adicionalmente, se examinará un fenómeno descubierto durante el análisis exploratorio de los datos: cuando el costo de los siniestros supera el monto de los 900 euros, la cantidad de siniestros aumenta de forma abrupta, interrumpiendo el comportamiento decreciente mostrado hasta ese valor; así, se pretende determinar qué variables inciden en el fenómeno detallado y desarrollar un análisis de distribución mixta.

Dado que el objetivo del proyecto considera variables cuantitativas y cualitativas, el manejo de las mismas difiere. En el caso de las variables cuantitativas, se acudirá al análisis de correlación para estudiar su relación con la frecuencia y la severidad de los siniestros; mientras que en el caso de las variables cualitativas, que además son categóricas, se desarrollará un análisis segmentado por grupos: se estudiará el comportamiento de las categorías contenidas en cada variable cualitativa, respecto a la frecuencia y la severidad de los siniestros, apoyándose en un análisis principalmente gráfico.

Por otro lado, es importante destacar que tras una revisión literaria mediante búsquedas a partir de palabras clave como frecuencia, severidad, cantidad de reclamos y seguros automovilísticos; se identificó que la mayoría de las producciones gira en torno a la predicción del riesgo. En vista de lo anterior, el conocimiento producido a través del desarrollo de este proyecto cubrirá un espacio que actualmente está vacío: la indagación en la manera en que las variables del entorno asegurador automovilístico se relacionan con la frecuencia y la severidad de los siniestros. Dicho conocimiento no solo adquiere la relevancia académica enunciada, sino que además proporciona información de utilidad para las aseguradoras automotrices, al brindarles un mayor conocimiento sobre los aspectos que potencialmente podrían disparar el pago de obligaciones con montos elevados y así puedan resguardar su capacidad de pago.

Finalmente, la estructura del proyecto se compone de tres secciones: la metodología, los resultados y las conclusiones. En la sección de la metodología se explicarán tanto los pasos como las herramientas empleadas para desarrollar la investigación. Después, en la sección de resultados se expondrán los principales hallazgos que responden al objetivo de investigación planteado. Por último, en la sección de conclusiones se enunciarán las observaciones emitidas a raíz de los descubrimientos.

METODOLOGÍA

El punto de partida de la metodología consistió en que las variables de la siniestralidad no presentan un comportamiento simple: la frecuencia corresponde a una variable de conteo, mientras que la severidad corresponde a una variable continua no negativa. Asimismo, el análisis descriptivo permitió identificar una alta concentración de ceros, una distribución asimétrica hacia la derecha y la presencia de valores extremos en el costo anual de los siniestros. Tales características hicieron necesaria una combinación de métodos descriptivos, comparativos y de modelación exploratoria.

DATOS

La base de datos utilizada corresponde al conjunto de datos de Lledó & Pavía (2024), disponible en Mendeley Data (DOI: 10.17632/5cxyb5fp4f.2). Mediante una investigación en openICPSR se determinó que el origen geográfico de la base corresponde a España, por lo que la divisa utilizada para las variables monetarias es el euro. La base contiene 105.555 registros y 34 variables, correspondientes a 53.502 asegu-

rados únicos, con un promedio de 1,97 registros por asegurado. La información cubre contratos desde 1980 hasta renovaciones registradas en 2018, e incluye cuatro tipos de vehículo: motocicleta, turismo, furgoneta y agrícola.

Se identificaron valores faltantes en tres variables. *Date_lapse* presentó 70.408 valores faltantes (66,7%) y se excluyó del análisis, al no ser indispensable para satisfacer el objetivo de la investigación. *Length* presentó 10.329 valores faltantes (9,79%) y se imputó mediante la mediana según el tipo de vehículo. *Type_fuel* presentó 1.764 valores faltantes (1,67%) y los registros correspondientes se eliminaron.

Para el análisis se seleccionaron variables relacionadas con tres dimensiones: las características del asegurado (edad, *Seniority*, antigüedad de la licencia de conducir), las características del vehículo (potencia, valor, peso, largo) y el historial de siniestros (*N_claims_history*, *R_Claims_history*), además de las variables centrales *N_claims_year* y *Cost_claims_year*, que permiten estudiar la frecuencia y la severidad anual de los siniestros, respectivamente.

FORMULACIÓN DE LOS MÉTODOS

La metodología se organizó en cuatro métodos complementarios: el análisis descriptivo de la frecuencia y la severidad de los siniestros; el estudio de las asociaciones entre las variables cuantitativas mediante el coeficiente de correlación de Spearman; la comparación entre grupos definidos a partir de las variables categóricas; y el análisis del umbral de 900 euros mediante una distribución mixta junto al ajuste de distribuciones paramétricas. Esta organización permitió avanzar desde una descripción general de los datos hacia un análisis más específico de los reclamos de alta severidad, en respuesta a la alta concentración de ceros, la asimetría hacia la derecha y los valores extremos observados.

Para el análisis descriptivo de la frecuencia y la severidad se denota $N_i = N_claims_year_i$ como la cantidad de siniestros reportados por el asegurado i durante el año, por otro lado, $Y_i = Cost_claims_year_i$ denota el costo anual de los siniestros asociado a ese registro. Dicha separación fue necesaria de acuerdo con Frees (2021), dado que ambas variables tienen naturalezas estadísticas distintas.

En lo que respecta a la frecuencia, se calculó para cada cantidad posible de siniestros k , la frecuencia absoluta $f_k = \{i : N_i = k\}$ y la frecuencia relativa $p_k = f_k/n$, además de la proporción de asegurados sin siniestros $\hat{p}_0 = \{i : N_i = 0\}/n$. También se calculó el índice de sobredispersión $D = Var(N_i)/E(N_i)$. Para la severidad se calculó la proporción de registros con costo igual a cero, $\hat{q}_0 = \{i : Y_i = 0\}/n$, y se analizó por separado el subconjunto de costos positivos $Y_i | Y_i > 0$, sobre el cual se calcularon las medidas de tendencia central y dispersión, dando un mayor peso a la mediana dada su menor sensibilidad a los valores extremos. El análisis visual se realizó mediante histogramas y boxplots, restringiendo en algunos gráficos los costos positivos a valores menores o iguales a 5.000 euros únicamente con fines de legibilidad.

La aplicación de este método mostró que el 81,21% de los registros no presentó siniestros durante el año: mediana de N_i igual a cero, con un promedio de 0,40 siniestros anuales y un máximo de 25. El costo promedio anual fue de 155,60 euros, con mediana igual a cero y un máximo de 260.853,24 euros, lo que confirma la concentración de la distribución en cero y la presencia de reclamos de un monto elevado. Respecto al umbral de 900 euros, no se registraron observaciones con costo exactamente igual a dicho valor, sin embargo 3.779 registros, un 3,64%, presentaron costos superiores a 900 euros. Mediante el método

del rango intercuartílico (IQR), se identificó que *Cost_claims_year* y *N_claims_year* presentaron el mayor porcentaje de valores atípicos, 18,79% cada una, seguidas por *Weight*, *Power*, *R_Claims_history* y *Seniority*, con valores entre 7% y 9,7%, mientras que *edad*, *antigüedad_licencia* y *edad_vehículo* mostraron escasos valores atípicos.

La comparación según el tipo de vehículo mostró que los vehículos de turismo representan casi el 80% de los registros, seguidos por las furgonetas con 12,73% y las motocicletas 6,61%. Las furgonetas presentaron el mayor promedio de siniestros: 0,568 y el costo promedio más alto: 166,35 euros, mientras que los vehículos de turismo mostraron un costo promedio similar: 165,10 euros pero una frecuencia menor. Las categorías agrícola y motocicleta mostraron porcentajes muy altos sin siniestros, en particular la categoría agrícola presentó un 99,86%. Según la zona de circulación, el 72,7% de los registros corresponde a la zona rural y el 27,3% a la zona urbana. No obstante, la zona urbana presentó un mayor promedio de siniestros: 0,458 frente a 0,376 y un costo promedio más alto: 175,56 euros frente a 148,10 euros, aunque la mediana del costo fue cero en ambas zonas.

El segundo método consistió en estudiar la asociación entre las variables cuantitativas del asegurado o del vehículo con las variables de la siniestralidad, con el propósito de identificar patrones de asociación exploratorios, sin establecer relaciones causales. Antes de calcular las correlaciones, se evaluó la normalidad de la variable de la frecuencia mediante la prueba de Shapiro-Wilk sobre una muestra de 5.000 observaciones. Dado que la prueba rechazó la normalidad, y considerando la alta concentración de ceros, la asimetría y los valores extremos, se descartó el coeficiente de Pearson y se utilizó únicamente el coeficiente de correlación de Spearman, definido como la correlación de Pearson aplicada a los rangos de las variables:

$$\rho_s = \frac{\sum_{i=1}^n (R(X_i) - \overline{R(X)})(R(Z_i) - \overline{R(Z)})}{\sqrt{\sum_{i=1}^n (R(X_i) - \overline{R(X)})^2} \sqrt{\sum_{i=1}^n (R(Z_i) - \overline{R(Z)})^2}}.$$

De acuerdo con Vinuesa (2016), el coeficiente resultó adecuado porque se basa en rangos y permite evaluar asociaciones monótonas sin exigir normalidad ni linealidad. Respecto a Kendall, Spearman resultó conveniente por el tamaño de la base de datos y por ofrecer una medida de interpretación directa. Las correlaciones se calcularon en R mediante *cor.test()* con el método *spearman*, y se presentaron en una matriz de correlación, la cual también permitió un diagnóstico preliminar de la multicolinealidad entre las variables explicativas.

Para complementar la estimación puntual, se construyeron intervalos de confianza al 95 % mediante la transformación z de Fisher, $z_{\hat{\rho}} = \text{arctanh}(\hat{\rho})$, bajo la cual $z_{\hat{\rho}} \sim N(\text{arctanh}(\rho), \frac{1}{n-3})$, de acuerdo con el enfoque analítico de Ruscio (2008). El intervalo en la escala transformada, $[z_{\hat{\rho}} - z_{0.975}/\sqrt{n-3}, z_{\hat{\rho}} + z_{0.975}/\sqrt{n-3}]$, se regresó a la escala original aplicando la función tangente hiperbólica. La interpretación se realizó de la siguiente manera: si el intervalo contenía el cero, la asociación se consideró débil o incierta; si el intervalo se mantuvo completamente por encima de cero, se interpretó como evidencia de asociación positiva; y si se mantuvo completamente por debajo de cero, como evidencia de asociación negativa.

El tercer método consistió en comparar la frecuencia y la severidad entre los grupos definidos a partir de las variables categóricas: el tipo de vehículo y zona de circulación, dado que estas características

no podían analizarse mediante las correlaciones. Para cada grupo g se calculó la frecuencia promedio de siniestros $\bar{N}_g = \frac{1}{n_g} \sum_{X_i=g} N_i$ y la proporción de asegurados sin siniestros $\hat{p}_{0,g}$. Para la severidad, se calculó la proporción de registros con costo positivo $\hat{q}_g$ dentro de cada grupo, y sobre el subconjunto $Y_i | (Y_i > 0, X_i = g)$ se calcularon medidas descriptivas, dando un mayor peso a la mediana y los cuartiles por la asimetría de la variable. Los resultados se complementaron con gráficos de barras y boxplots del costo anual positivo, filtrando y restringiendo el eje a valores menores o iguales a 5.000 euros solo con fines de visualización.

El cuarto método consistió en analizar el comportamiento de los registros cuyo costo anual alcanzó o superó los 900 euros. A partir de los resultados exploratorios: la distribución asimétrica del costo anual de los siniestros hacia la derecha con un pico pronunciado alrededor de los 900 euros, se decidió emprender un análisis de distribución mixta:

$$Y_i \sim \pi_0 \delta_0 + \pi_1 F_1(y | \theta_1) + \pi_2 F_2(y | \theta_2), \quad \pi_0 + \pi_1 + \pi_2 = 1,$$

donde δ_0 representa la masa puntual en cero, F_1 los costos positivos moderados y F_2 los costos altos. Se definió la variable categórica $G_i \in \{0, 1, 2\}$ según $Y_i = 0$, $0 < Y_i < 900$ o $Y_i \geq 900$, respectivamente, y los pesos $\hat{\pi}_0, \hat{\pi}_1, \hat{\pi}_2$ se estimaron como las proporciones observadas en la muestra.

Para los componentes positivos se utilizó el paquete *fitdistrplus* de R de acuerdo con Delignette-Muller & Dutang (2015), para ajustar distribuciones mediante máxima verosimilitud y compararlas mediante el Criterio de Información de Akaike, $AIC = -2\ell(\hat{\theta}) + 2k$. Para los costos positivos menores a 900 euros se evaluaron como candidatas la Lognormal, la Gamma y la Weibull. Para los costos mayores o iguales a 900 euros, acotados por la cifra de 20.000 euros únicamente para el ajuste gráfico y paramétrico, sin excluir dichas observaciones del análisis general, se evaluaron la Lognormal, la Pareto y la Weibull.

En ambos componentes, la distribución Lognormal presentó el mejor ajuste. Esta selección se justificó, según Crow & Shimizu (1988), porque si $Y \sim \text{Lognormal}(\mu, \sigma^2)$ entonces $W = \ln(Y) \sim N(\mu, \sigma^2)$, lo que permitió trabajar en una escala aproximadamente normal y utilizar métodos estándar de inferencia. A partir de la muestra transformada $W_i = \ln(Y_i)$, se construyeron intervalos de confianza al 95% para μ .

Adicionalmente, se definió la variable indicadora $H_i = 1$ si $Y_i \geq 900$ y $H_i = 0$ en caso contrario, con la cual se compararon mediante boxplots variables cuantitativas como la edad, la antigüedad con la aseguradora, el historial de siniestros, el peso, la potencia y el valor del vehículo entre ambos grupos; el historial de siniestros mostró la diferencia visual más clara entre ambos grupos. También se calculó, para cada variable categórica, la proporción de reclamos con $H_i = 1$, $\hat{r}_g = \{i : X_i = g, Y_i \geq 900\} / n_g$, con el fin de identificar qué categorías de tipo de vehículo, zona o tipo de combustible concentraban una mayor proporción de reclamos de alta severidad.

RESULTADOS

Dado que el objetivo de la investigación aborda dos aspectos: la relación entre la edad del asegurado, la antigüedad con la aseguradora, el historial de siniestros y las características del vehículo: el valor, la potencia, el peso, el tipo y la zona de circulación, tanto con la frecuencia como con la severidad de los

siniestros; y el estudio del incremento abrupto en la cantidad de reclamos al momento que el costo de los mismos supera el monto de 900 euros; se optó por crear secciones diferenciadas para el abordaje de los resultados de cada componente, los cuales se detallan a continuación.

RELACIÓN ENTRE LAS VARIABLES DESCRITAS CON LA FRECUENCIA Y LA SEVERIDAD DE LOS SINIESTROS



El análisis de la relación entre las variables contempladas con la frecuencia y la severidad de los siniestros, se desarrolló a partir de dos métodos: el primer método corresponde al análisis de correlación para las variables cuantitativas, mientras que el segundo método consiste en un análisis comparativo entre grupos definidos a partir de las variables categóricas, como la zona de circulación y el tipo de vehículo.

En primer lugar, se halló que las variables del valor del vehículo, la potencia del vehículo, el peso del vehículo, la antigüedad con la aseguradora y la edad del asegurado, poseen una correlación despreciable tanto con la frecuencia como con la severidad de los siniestros. El coeficiente de correlación obtenido fue estrictamente menor al valor absoluto de 0,1 en todos los casos, de manera que la relación de estas variables con la frecuencia y la severidad de los siniestros es despreciable. Asimismo, el resultado obtenido indica que no representan buenos prospectos de asociación con el cambio abrupto en la cantidad de reclamos cuando el monto de los mismos supera los 900 euros.

Similarmente, se identificó que la variable del historial de reclamos presenta una correlación mediana con la frecuencia y la severidad de los mismos. De acuerdo con Vinuesa (2016), el valor del coeficiente para una correlación mediana debe ser: $0,3 < |r| \leq 0,5$. El coeficiente de correlación obtenido para el historial de siniestros de acuerdo a la frecuencia y la severidad de los reclamos, es de 0,38 y 0,36 respectivamente, situándose en el rango especificado. Así, se determinó que el historial de siniestros posee una relación media con las variables respuesta.

Es importante destacar que los resultados hallados mediante el análisis de correlación, se estimaron a partir de intervalos de confianza al 95%.

En segundo lugar, se encontró que la frecuencia muestra un comportamiento diferenciado según la zona de circulación, mientras que la severidad no presenta diferencias notables en su comportamiento bajo dichas categorías. Los asegurados de las zonas urbanas presentan un mayor promedio en la frecuencia de la siniestralidad anual, en comparación con los asegurados de las zonas rurales. Además, las distribuciones del costo anual positivo son similares entre las zonas rurales y las zonas urbanas. Así, es posible afirmar que la zona de circulación tiene cierta asociación con la frecuencia de los siniestros, sin embargo, no es posible realizar la afirmación análoga respecto a la severidad de los siniestros. El resultado es consistente con lo esperado, dado que las zonas urbanas presentan mayor densidad de tráfico. Seguidamente, se presentan los gráficos que ilustran los resultados explicados.

Figura 1*Frecuencia promedio de siniestros por zona de circulación***Figura 2***Distribución del costo por zona de circulación*

En tercer lugar, se analizó la relación entre la variable del tipo de vehículo con la frecuencia y la severidad de los siniestros. Dado que el tipo de vehículo es una variable categórica, se efectuó una agrupación según las categorías de la variable. En consecuencia, se concluyó que los vehículos de turismo poseen un mayor costo anual de siniestros, en comparación a los otros tipos de vehículos, mientras que las furgonetas presentan una mayor frecuencia promedio de siniestros: 0,568. El hallazgo evidencia que el tipo de vehículo está asociado con la frecuencia y la severidad, donde los vehículos particulares o de turismo, tienen siniestros con un mayor costo anual, por otro lado, las furgonetas poseen una mayor cantidad de siniestros por año.

En síntesis, el análisis realizado muestra que las variables de las características asociadas a los asegurados y a los vehículos, poseen relaciones diferenciadas con la frecuencia y la severidad de los siniestros. Las variables de la edad del asegurado, la antigüedad con la aseguradora, el valor, la potencia y el peso del vehículo presentan relaciones despreciables con las variables respuesta; el caso contrario de la variable del historial de siniestros, la cual evidencia una asociación moderada con estas. Asimismo, las comparaciones entre grupos revelan que la frecuencia de los siniestros varía según la zona de circulación y el tipo de vehículo, mientras que la severidad muestra diferencias más limitadas en el caso de la zona de circulación, en lo que respecta al tipo de vehículo, los vehículos de turismo concentran la mayor severidad, es decir, el mayor costo anual.

ANÁLISIS DEL INCREMENTO ABRUPTO AL SUPERAR EL MONTO DE 900 EUROS

El análisis del incremento abrupto al superar el monto de 900 euros se compone de dos acciones: determinar qué variables inciden en el fenómeno detallado y desarrollar un análisis de distribución mixta. Respecto al primer componente se encontraron tres resultados particulares, los cuales se detallan como sigue.

INCIDENCIA DE LAS VARIABLES EN EL FENÓMENO BAJO ESTUDIO

En primer lugar, se calcularon los estadísticos descriptivos para el costo anual positivo de los sinies-

tros, es decir, los costos mayores a cero. Dichos estadísticos se calcularon para las clases de las variables categóricas: el tipo de vehículo, la zona de circulación y el tipo de combustible. A partir de los resultados obtenidos, se determinó que el tercer cuartil del costo positivo de los siniestros es exactamente 882 euros en todos los grupos analizados. El hecho de que el 75% de los siniestros con costo positivo se concentre por debajo de 882 euros, sugiere que el umbral de 900 euros no es arbitrario, sino que corresponde a un punto de corte estructural de la distribución del costo. Lo anterior refuerza la pertinencia metodológica de usar la cifra de 900 euros como separador entre las clases de costo medio y de costo alto en el modelo de la distribución mixta.

En segundo lugar, se descubrió que el tipo de vehículo se relaciona con la proporción de reclamos con costos superiores a los 900 euros, ya que las furgonetas y los vehículos de turismo concentraron los reclamos de alta severidad. Se calculó el promedio de la cantidad de reclamos con montos superiores a 900 euros, por cada clase de vehículo y así se obtuvo el hallazgo descrito. En consideración del presente resultado, se puede confirmar que el tipo de vehículo se asocia con el comportamiento de los costos alrededor del umbral de los 900 euros, ya que las furgonetas y los vehículos de turismo concentran las proporciones más altas de estos reclamos.

Similarmente, se determinó que los reclamos más costosos, aquellos que superan los 900 euros, se concentran en vehículos de características intermedias: los vehículos con pesos entre 1000 y 1500 kilogramos, longitudes entre 4,0 y 4,7 metros, potencias entre 70 y 130 caballos de fuerza, cilindrajes entre 1.400 y 2.000, así como cinco puertas, que corresponden a las cuatro puertas y la cajuela. Tal resultado sugiere que el aumento abrupto en el costo no está asociado en su mayoría con vehículos especiales, sino que está asociado principalmente con vehículos de uso común: los de turismo, los familiares o incluso los cotidianos.

En síntesis, los resultados obtenidos sugieren que el umbral de 900 euros constituye un punto de referencia relevante dentro de la estructura de los costos de los siniestros: coincide con un valor cercano al tercer cuartil de la distribución en todos los grupos analizados. Asimismo, se identificó que el tipo de vehículo desempeña un papel importante en los reclamos de alta severidad, puesto que las furgonetas y los vehículos de turismo concentran una mayor proporción de casos por encima del umbral definido. Dicho hallazgo se complementa con la observación de que los reclamos más costosos no se asocian principalmente con los vehículos especiales, sino con los vehículos que poseen características intermedias.

ANÁLISIS DE DISTRIBUCIÓN MIXTA

Para estudiar el comportamiento del costo anual en torno al umbral de 900 euros, se implementó un modelo de distribución mixta, separando los registros en tres componentes: los costos nulos, los costos moderados, cuyos valores son mayores a cero y menores a 900 euros; y los costos altos, cuyos montos son mayores o iguales a 900 euros y son menores o iguales a 20.000 euros. A partir de la división planteada se encontraron dos resultados particulares, los cuales se detallan como sigue.

En primer lugar, se determinó que la distribución que presenta un mejor ajuste para los costos moderados corresponde a la distribución Lognormal, al obtener un Criterio de Información de Akaike (AIC) de 211.339,9. Esta distribución fue comparada con la distribución Gamma, la cual obtuvo un AIC de 212.684,5, con una diferencia de 1.344,6 respecto a la Lognormal. En vista de lo anterior, se seleccionó la Lognormal para modelar los costos moderados. Mediante el paquete *fitdistrplus*, se recurrió a la función *fitdist()* para

calcular los parámetros de la distribución, los resultados fueron: $\text{meanlog} = 5,2785366$ y $\text{sdlog} = 0,9693318$.

En segundo lugar, para los costos altos se encontró que la distribución con un mejor es la distribución Lognormal, la cual obtuvo un AIC de 64.536,62. En este caso, dicha distribución se comparó con la distribución de Pareto, que resultó en un AIC de 66.422,61, con una diferencia de 1.885,99 respecto a la Lognormal. Además, a través del uso del mismo paquete se concluyó que los parámetros para esta distribución son: $\text{meanlog} = 7,5571894$ y $\text{sdlog} = 0,6816524$.

Finalmente, es importante aclarar que la cota superior de 20.000 euros se fijó con el objetivo de facilitar el ajuste, puesto que las observaciones con costos superiores a tal cifra representan valores extremos aislados, los cuales pueden potencialmente distorsionar las estimaciones.

En síntesis, el análisis de distribución mixta permitió caracterizar el comportamiento de los costos anuales alrededor del umbral de 900 euros. Los resultados evidenciaron que la distribución Lognormal proporciona el mejor ajuste tanto para los costos moderados como para los costos altos, superando a las distribuciones Gamma y Pareto según el criterio AIC. Asimismo, la decisión de segmentar los datos y de excluir a las observaciones con montos superiores a 20.000 euros, favoreció la obtención de estimaciones más estables.

CONCLUSIONES

La presente investigación propuso analizar la relación entre las variables de la edad del asegurado, la antigüedad con la aseguradora, el historial de siniestros y las características del vehículo, con la frecuencia y la severidad de los siniestros; además de estudiar el incremento abrupto en la cantidad de reclamos cuando el costo de los mismos alcanza los 900 euros. Se esperaba encontrar que las variables detalladas presentaran una asociación significativa con la frecuencia y la severidad, igualmente, se esperaba que el fenómeno bajo estudio estuviera asociado a ciertas características del vehículo. Los resultados coinciden parcialmente con las expectativas, pues se encontró que el tipo de vehículo influye tanto en la frecuencia como en la severidad de los siniestros; el historial de siniestros se asocia medianamente con la siniestralidad; algunas variables del vehículo: el valor, la potencia y el peso, al igual que algunas variables del asegurado: la edad y la antigüedad con la aseguradora, tienen una correlación despreciable tanto con la frecuencia como con la severidad.

La metodología utilizada permitió abordar el objetivo de la investigación de manera satisfactoria. La misma se dividió en cuatro métodos complementarios: el análisis descriptivo de la base de datos, el cálculo de las correlaciones de Spearman con intervalos de confianza para las variables numéricas, la comparación entre grupos y la creación de una distribución mixta de tres componentes ajustada con el paquete *fitdistrplus* de R. Por otro lado, el trabajo resuelve un vacío de conocimiento, ya que no solo propone el estudio de la intervención de ciertas variables en la siniestralidad, sino que también implementa el análisis de un fenómeno específico: el aumento de reclamos a partir del umbral de 900 euros. Lo anterior constituye un aspecto no abordado en la literatura estándar, la cual suele concentrarse en modelos de predicción de riesgo más generales.

Finalmente, para futuras investigaciones se recomienda optar por la construcción de un aprendizaje práctico, de manera que las producciones generadas no enfoquen sus esfuerzos en un área meramente teórica, sino que el conocimiento hallado se aplique de igual manera a escenarios reales, con tal de ofrecer una mayor

perspectiva a las entidades pertinentes y a los profesionales que se desarrollan en el campo contemplado. Asimismo, sería de gran valor aplicar este enfoque en distintas bases de datos de aseguradoras españolas o europeas, con el fin de identificar si existe un patrón: el aumento abrupto de la cantidad de reclamos a partir de un costo específico.

AGRADECIMIENTOS

Primeramente, deseamos externar nuestro profundo agradecimiento a la Universidad de Costa Rica, un hogar educativo que promueve la excelencia, la creatividad y el pleno desarrollo de sus estudiantes. Durante estos tres años de formación académica hemos recibido de su parte un cálido recibimiento, asimismo, su compromiso con la formación integral de profesionales ha fortalecido en nosotros no solo nuestros conocimientos y habilidades, sino también un amplio sentido de responsabilidad social.

Finalmente, agradecemos al docente Maikol Solís Chacón, quien ha sido nuestro mentor a lo largo del proceso. Su disposición para brindar apoyo y su motivación por compartir sus vastos conocimientos, se reflejó de manera directa en la construcción de una investigación sólida y en un entorno de aprendizaje práctico.

REFERENCIAS

- Crow, E. L., & Shimizu, K. (Eds.). (1988). *Lognormal Distributions: Theory and Applications*. Marcel Dekker. <https://eudml.org/doc/176358>
- Delignette-Muller, M. L., & Dutang, C. (2015). fitdistrplus: An R Package for Fitting Distributions. *Journal of Statistical Software*, 64(4), 1-34. <https://www.jstatsoft.org/article/view/v064i04>
- Frees, E. W. (2021). *Loss Data Analytics*. Springer. <https://openacttexts.github.io/LDASpanish/>
- Lledó, J., & Pavia, J. M. (2024). *Dataset of an actual motor vehicle insurance portfolio* (Versión 2). Mendeley Data. <https://doi.org/10.17632/5cxyb5fp4f.2>
- Ruscio, J. (2008). Constructing Confidence Intervals for Spearman's Rank Correlation with Ordinal Data: A Simulation Study Comparing Analytic and Bootstrap Methods. *Journal of Modern Applied Statistical Methods*, 7(2), 416-434. <https://digitalcommons.wayne.edu/cgi/viewcontent.cgi?article=1455&context=jmasm>
- Vinuesa, P. (2016). *Correlación: teoría y práctica*. https://www.ccg.unam.mx/~vinuesa/R4biosciences/docs/Tema8/_correlacion.pdf

ANEXOS

La totalidad del código de programación necesario para satisfacer el objetivo del proyecto se desarrolló a partir del lenguaje de programación R. El mismo puede ser consultado en el repositorio de GitHub: <https://github.com/CA303-I-2026/Grupo-3-p-0.05>